Диагностика рака молочной железы в Висконсине

Источник данных: https://www.kaggle.com/uciml/breast-cancer-wisconsin-data (https://www.kaggle.com/uciml/breast-cancer-wisconsin-data)

В этом ноутбуке будут опробованы различные прогностические модели, чтобы увидеть, насколько они точны при определении является ли опухоль злокачественной или доброкачественной.

План:

- Визуализировать данные для упрощения понимания.
- Понять, насколько несбалансированн имеющийся набор данных.
- Создать соотношение 50/50 для классов (диагнозов) злокачественных и доброкачественных опухолей.
- Опробовать несколько классификаторов и определить, какой из них является наиболее точным.
- Создать нейронную сеть и сравнить точность с лучшим классификатором.
- Понять распространенные ошибки, допускаемые при использовании разбалансированных наборов данных.

Содержание:

Описание и визуализация данных

In [1]:

```
# Импорт библиотек

import numpy as np
import pandas as pd
import tensorflow as tf
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.manifold import TSNE
from sklearn.decomposition import PCA, TruncatedSVD
import matplotlib.patches as mpatches
import time

# Классификаторы
from sklearn.linear_model import LogisticRegression
from sklearn.svm import SVC
from sklearn.neighbors import KNeighborsClassifier
from sklearn.tree import DecisionTreeClassifier
from sklearn.ensemble import RandomForestClassifier
import collections


# Другие
from sklearn.model_selection import train_test_split
from sklearn.pipeline import make_pipeline
from imblearn.pipeline import make_pipeline as imbalanced_make_pipeline
from imblearn.over_sampling import SMOTE
from imblearn.under_sampling import NearMiss
from imblearn.metrics import classification_report_imbalanced
from sklearn.metrics import precision_score, recall_score, f1_score, roc_auc_score, accurac
from collections import Counter
from sklearn.model_selection import KFold, StratifiedKFold
import warnings
warnings.filterwarnings("ignore")
```

Описание

In [2]:

```
df = pd.read_csv('data.csv')
df.head()
```

Out[2]:

	id	diagnosis	radius_mean	texture_mean	perimeter_mean	area_mean	smoothnes
0	842302	M	17.99	10.38	122.80	1001.0	
1	842517	M	20.57	17.77	132.90	1326.0	
2	84300903	M	19.69	21.25	130.00	1203.0	
3	84348301	M	11.42	20.38	77.58	386.1	
4	84358402	M	20.29	14.34	135.10	1297.0	

5 rows × 33 columns

In [3]:

```
# Заменяем символьные значения на численные в столбце 'diagnosis': 1 - злокачественные, 0 -
df['diagnosis'] = df['diagnosis'].map({'M': 1, 'B': 0})
# Удаляем столбцы, которые не понадобятся
del df['id']
del df['Unnamed: 32']

df.head()
```

Out[3]:

	diagnosis	radius_mean	texture_mean	perimeter_mean	area_mean	smoothness_mean	com
0	1	17.99	10.38	122.80	1001.0	0.11840	
1	1	20.57	17.77	132.90	1326.0	0.08474	
2	1	19.69	21.25	130.00	1203.0	0.10960	
3	1	11.42	20.38	77.58	386.1	0.14250	
4	1	20.29	14.34	135.10	1297.0	0.10030	

5 rows × 31 columns

In [4]:

```
# Общая статистика df
df.describe()
```

Out[4]:

	diagnosis	radius_mean	texture_mean	perimeter_mean	area_mean	smoothness_mean
count	569.000000	569.000000	569.000000	569.000000	569.000000	569.000000
mean	0.372583	14.127292	19.289649	91.969033	654.889104	0.096360
std	0.483918	3.524049	4.301036	24.298981	351.914129	0.014064
min	0.000000	6.981000	9.710000	43.790000	143.500000	0.052630
25%	0.000000	11.700000	16.170000	75.170000	420.300000	0.086370
50%	0.000000	13.370000	18.840000	86.240000	551.100000	0.095870
75%	1.000000	15.780000	21.800000	104.100000	782.700000	0.105300
max	1.000000	28.110000	39.280000	188.500000	2501.000000	0.163400

8 rows × 31 columns

In [5]:

```
# количество значений Null
df.isnull().sum().max()
```

Out[5]:

```
0
```

Названия столбцов

ID больного и диагноз:
1 - id - идентификационный номер пациента
2 - diagnosis - диагноз тканей молочной железы (1 - злокачественная, 0 - доброкачественная)

Среднии значения признаков:
3 - radius mean - среднее расстояние от центра до точек по периметру
4 - texture mean - среднее значение текстуры по серой шкалы
5 - perimeter mean - средний значение периметра
6 - area mean - средняя площадь поверхности
7 - smoothness mean - среднее локального изменения длины радиуса
8 - compactness mean - (среднее периметра ^ 2 / площадь) - 1,0
9 - concavity mean - средний вес вогнутых частей контура
10 - concave points mean - среднее число вогнутых частей контура
11 - symmetry mean - среднее значение симметрии
12 - fractal dimension mean - среднее значение для фрактальной размерности пограничной линии

СКО (среднеквадратическое отклоненние) признаков:
13 - radius se - СКО расстояния от центра до точек по периметру
14 - texture se - СКО значений текстуры по серой шкале
15 - perimeter se - СКО длины перимета
16 - area se - СКО лощади поверхности
17 - smoothness se - СКО локального изменения длины радиуса
18 - compactness se - СКО по параметру = (периметр ^ 2 / площадь) - 1,0
19 - concavity se - СКО веса вогнутых частей контура
20 - concave points se - СКО количества вогнутых частей контура
21 - symmetry se - СКО симметрии
22 - fractal dimension se - СКО фрактальной размерности пограничной линии

Наибольшие значения признаков:
23 - radius worst - наибольшее значение среднего расстояния от центра до точек по периметру
24 - texture worst - наибольшее значение стандартного отклонения значений серой шкалы
25 - perimeter worst - наибольшее значение длины перимета
26 - area worst - наибольшее значение площади поверхности
27 - smoothness worst - наибольшее значение локального изменения длины радиуса
28 - compactness worst - наибольшее значение параметра = (периметр ^ 2 / площадь) - 1,0
29 - concavity worst - наибольшее значение веса вогнутых частей контура
30 - concave points worst - наибольшее значение количества вогнутых частей контура
31 - symmetry worst - наибольшее значение симметрии
32 - fractal dimension worst - наибольшее значение фрактальной размерности пограничной линии

In [6]:

```
# Создадим массивы с названиями столбцов в df и названиями для отображения на графиках

# Массив с названиями колонок
column_names = ['diagnosis', 'radius_mean', 'texture_mean', 'perimeter_mean', 'area_mean',
                'compactness_mean', 'concavity_mean', 'concave points_mean', 'symmetry_mean
                'radius_se', 'texture_se', 'perimeter_se', 'area_se', 'smoothness_se', 'com
                'concave points_se', 'symmetry_se', 'fractal_dimension_se', 'radius_worst',
                'perimeter_worst', 'area_worst', 'smoothness_worst', 'compactness_worst', '
                'concave points_worst', 'symmetry_worst', 'fractal_dimension_worst']
# Массив с краткими названиями на русском. Потом пригодиться
rus_titles = ['Диагноз','Средний радиус','Среднее значение текстуры','Средний периметр','Ср
              'Среднее значение гладкости','Среднее значение параметра \n P**2 / S - 1','Сре
              'Среднее число вогнутых частей','Среднее значение симметрии','Средняя фрактал
              'СКО радиуса','СКО значения текстуры','СКО периметра','СКО площади','СКО значе
              'СКО значения параметра \n P^2/S - 1','СКО веса вогнутых частей','СКО числа во
              'СКО значения симметрии','СКО фрактальной размерности \n пограничной линии','Н
              'Наибольшее значение текстуры','Наибольший периметр','Наибольшая площадь','Наи
              'Наибольшее значение параметра \n P^2/S - 1','Наибольший вес вогнутых частей',
              'Наибольшее значение симметрии','Наибольшая фрактальная \n размерность погран

print(len(column_names), len(rus_titles))
```

```
31 31
```

Визуализация

In [7]:

```
from pandas.plotting import scatter_matrix
colors = {0: 'b', 1: 'r'}

scatter_matrix(df.iloc[:,1:11], # матрица для колонок под индексами 1:11
               # размер картинки
               figsize=(20, 20),
               # плотность вместо гистограммы на диагонали
               diagonal='kde',
               # цвета классов
               c=df['diagnosis'].replace(colors),
               # степень прозрачности точек
               alpha=0.2,
              );
```

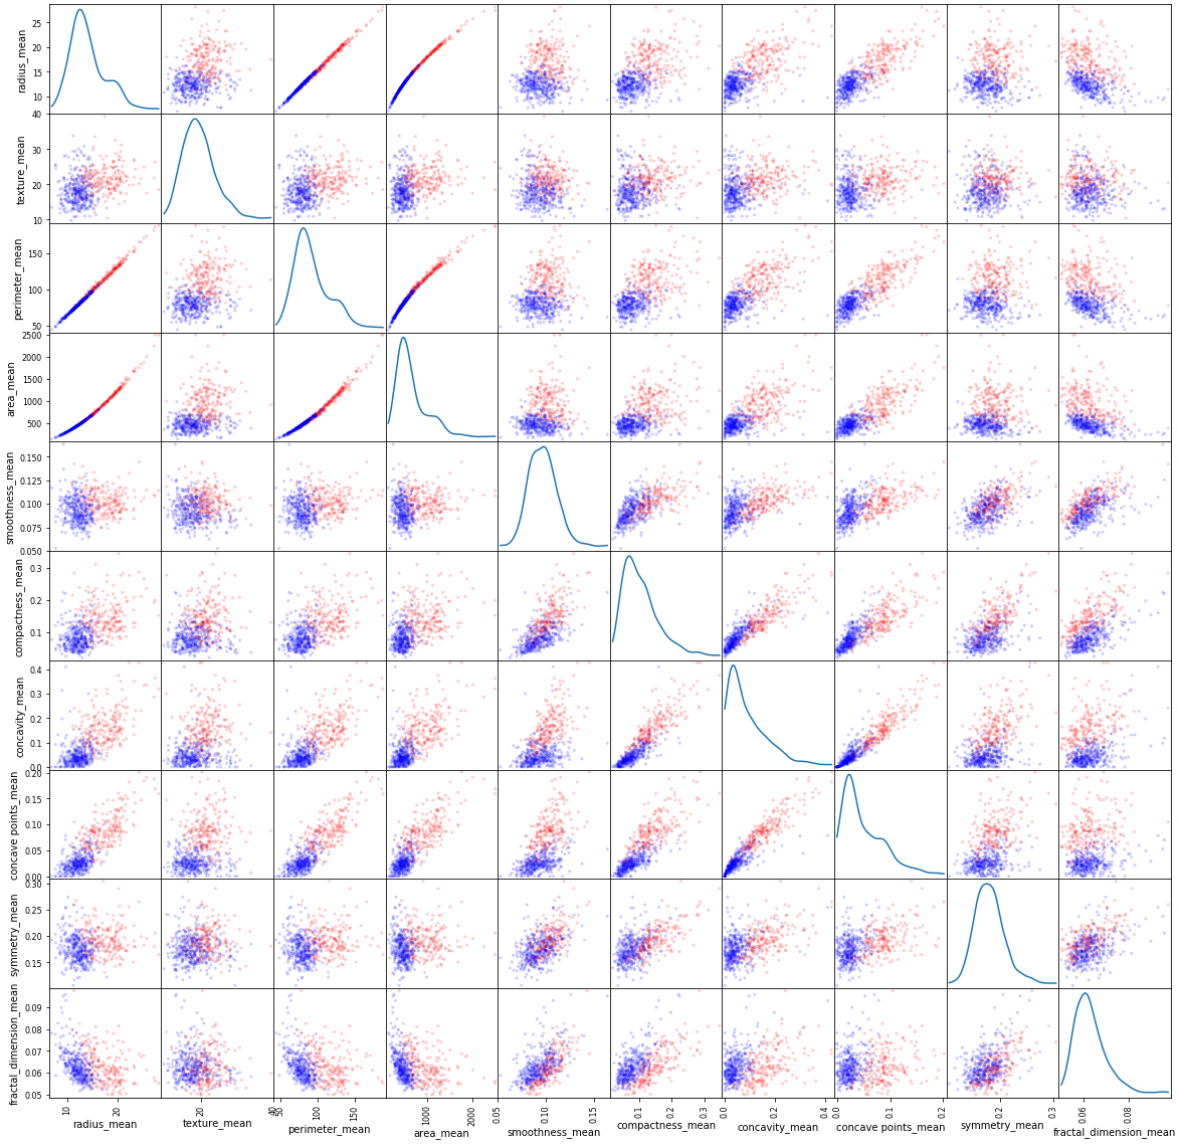

In [8]:

```
scatter_matrix(df.iloc[:,11:21],
               figsize=(20, 20),
               diagonal='kde',
               c=df['diagnosis'].replace(colors),
               alpha=0.2,
              );
```

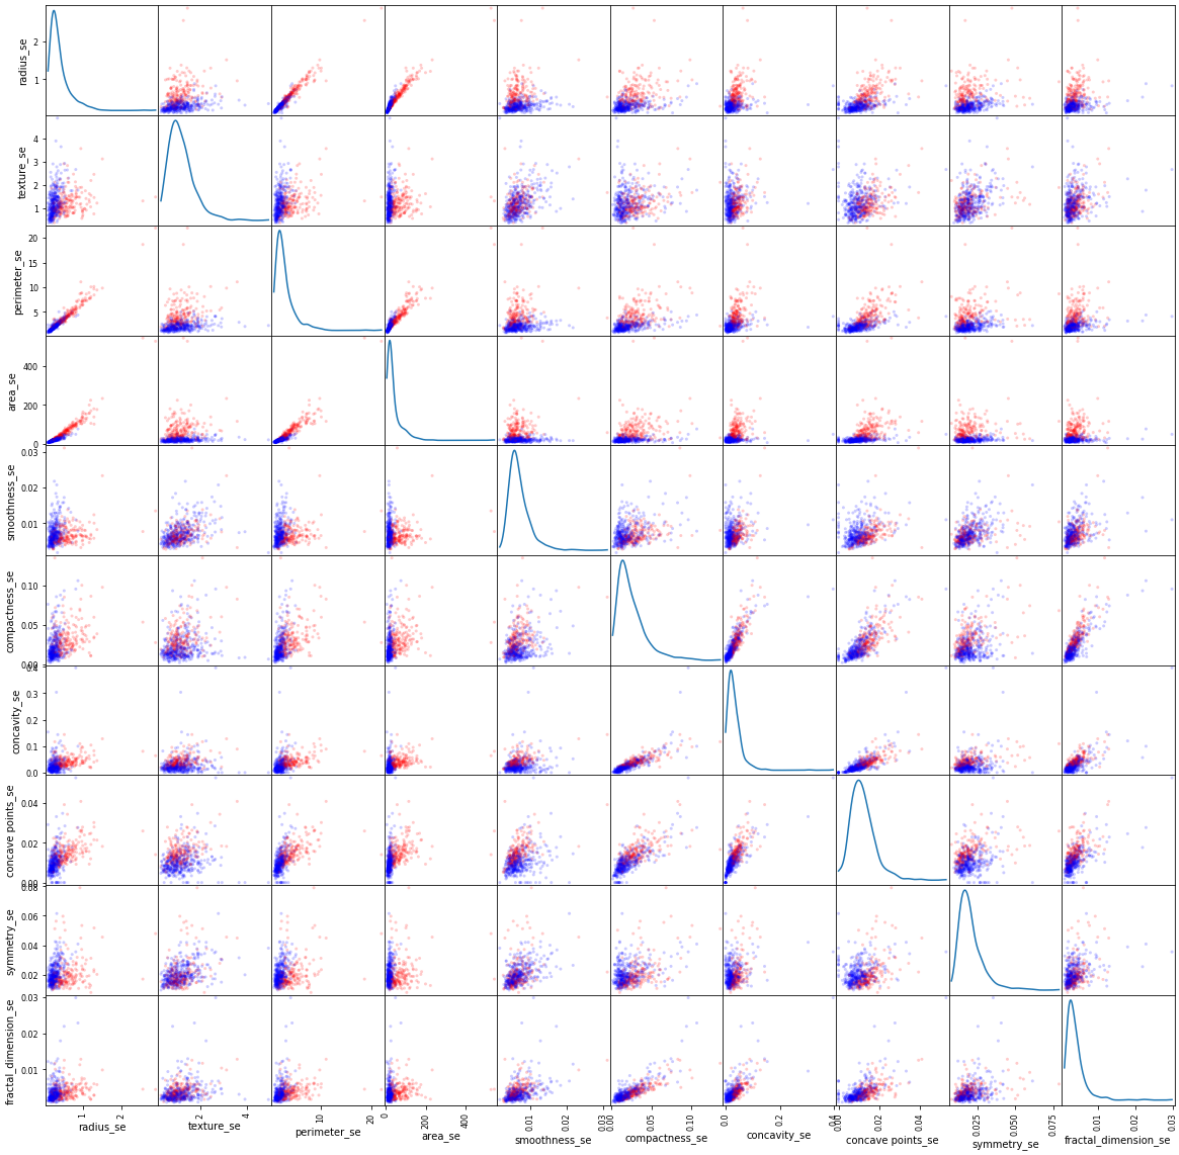

In [9]:

```
scatter_matrix(df.iloc[:,21:31],
               figsize=(20, 20),
               diagonal='kde',
               c=df['diagnosis'].replace(colors),
               alpha=0.2,
              );
```

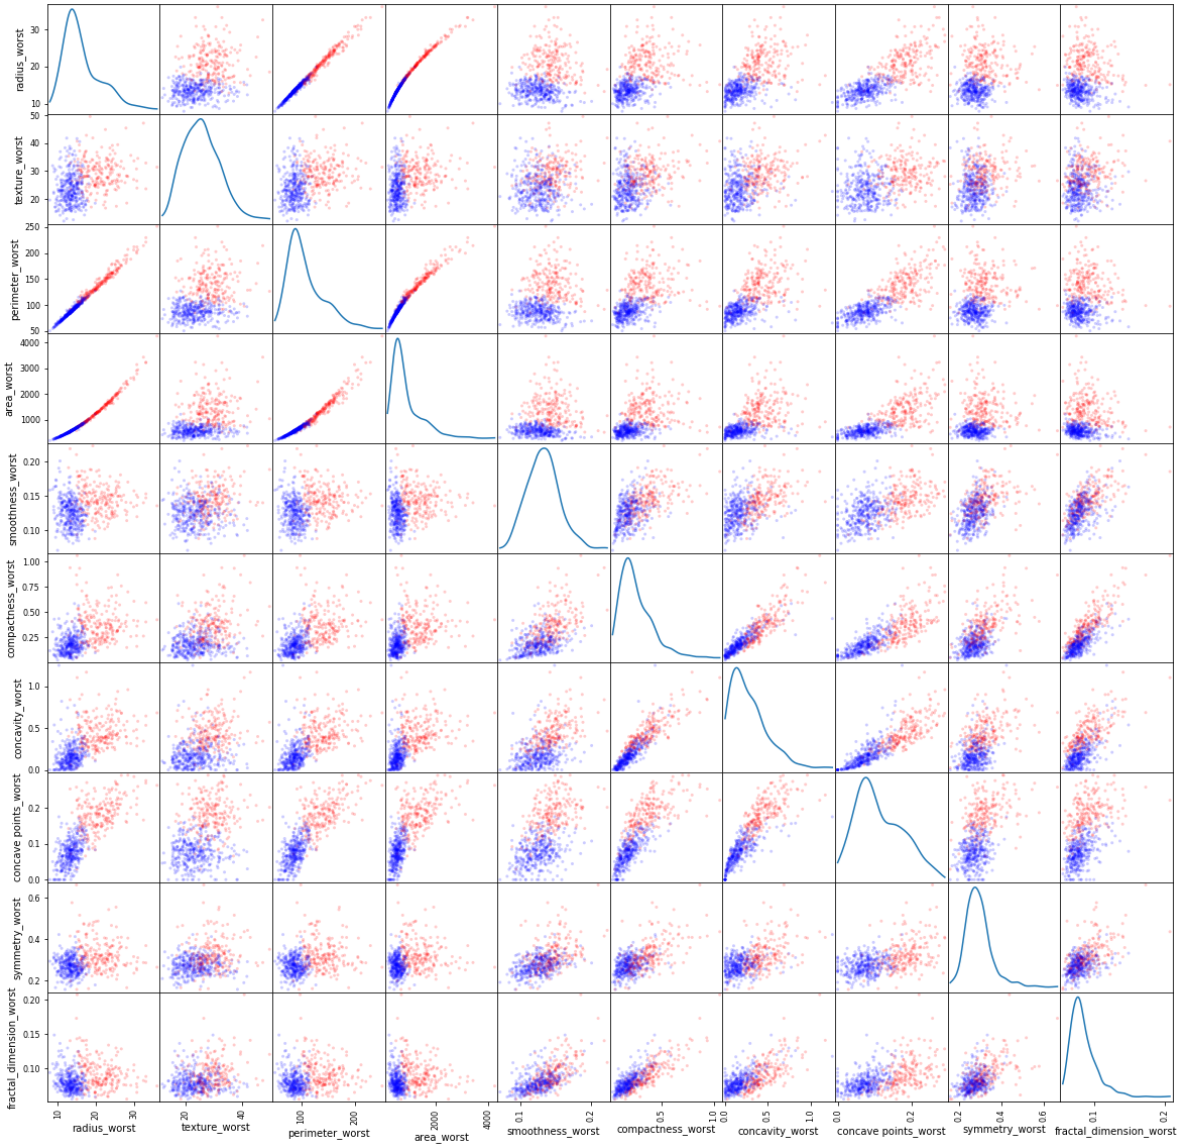

На "scatter matrix" видно, что точки зависимости периметра от радиуса с большой точностью ложатся на одну прямую (P = 2 Pi r), а точки зависимости площади от радиуса на линию параболы (S = Pi r^2). Такое расположение точек итих зависимостей возможно в двух случаях: 1 - значения площади и периметра были получены путем вычисления, 2 - геометрические формы опухолей очень правильные. Второе предположение опровергается наличием значительных разбросов точек по другим параметрам, характеризующим геометрию формы. Незначительный разброс точек для зависомостей периметра и

площади от радиуса скорее всего обусловлен округлением чесел (можно это доказать, но этого делать в данном случае не обязательно). Для более более ясной понимания данных посмотрим на митрицу корреляции:

Распределение по классам

In [10]:

```
# Классы разбалансированны
print('Классификация опухолей молочной железы:')
print('доброкачественные состовляют ',
      round(df['diagnosis'].value_counts()[0]/len(df) * 100,2), '% диагнозов;')
print('злокачественные состовляют ', round(df['diagnosis'].value_counts()[1]/len(df) * 100,
```

```
Классификация опухолей молочной железы:
доброкачественные состовляют  62.74 % диагнозов;
злокачественные состовляют  37.26 % диагнозов.
```

In [11]:

```
# Посмотрим как выглядит соотношение классов
colors = ["#0101DF", "#DF0101"]

sns.countplot('diagnosis', data=df, palette=colors)
plt.title('Распределение диагнозов \n (0: Доброкачественная || 1: Злокачественная)', fontsi
```

Out[11]:

```
Text(0.5, 1.0, 'Распределение диагнозов \n (0: Доброкачественная || 1: Злока
чественная)')
```

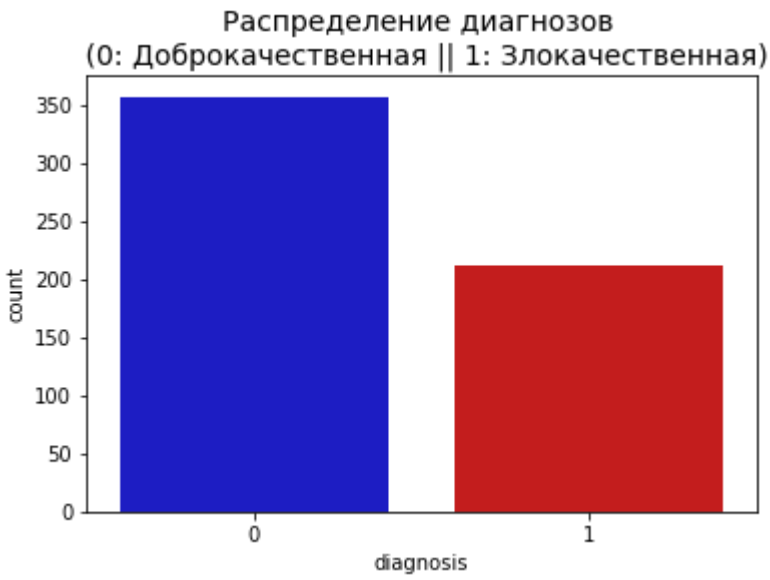

Корреляция

In [12]:

```
# Т.к. количество диагнозов доброкачественных и злокачественных опухолей отличается,
# нам надо выровнить их для того, чтобы получить корректные коэффициенты корреляции

# Перемешаем данные перед созданием подвыборок

df_for_mcor = df.loc[:]
df_for_mcor = df_for_mcor.sample(frac=1).reset_index(drop=True)

# M = malignant (злокачественная), B = benign (доброкачественная)
# количество строк для класса злокачественных опухолей - 212.
malignant_df_for_mcor = df_for_mcor.loc[df['diagnosis'] == 1]
benign_df_for_mcor = df_for_mcor.loc[df['diagnosis'] == 0][:212]

# объединение malignant_df и benign_df
normal_distributed_df_for_mcor = pd.concat([malignant_df_for_mcor, benign_df_for_mcor])

# Перемешиваем строки в наборе данных
new_df_for_mcor = normal_distributed_df_for_mcor.sample(frac=1).reset_index(drop=True)
```

In [13]:

```
new_df_for_mcor
```

Out[13]:

	diagnosis	radius_mean	texture_mean	perimeter_mean	area_mean	smoothness_mean	cc
0	1	19.000	18.91	123.40	1138.0	0.08217	
1	0	11.800	17.26	75.26	431.9	0.09087	
2	0	13.680	16.33	87.76	575.5	0.09277	
3	1	19.070	24.81	128.30	1104.0	0.09081	
4	1	17.060	21.00	111.80	918.6	0.11190	
...	...	...	...	...	...	...	
419	0	12.900	15.92	83.74	512.2	0.08677	
420	0	14.020	15.66	89.59	606.5	0.07966	
421	0	9.731	15.34	63.78	300.2	0.10720	
422	0	9.683	19.34	61.05	285.7	0.08491	
423	0	12.340	14.95	78.29	469.1	0.08682	

424 rows × 31 columns

In [14]:

```
# матрица корреляции для new_df_for_mcor (с равномерным распределением классов)

f = plt.figure(figsize=(19, 15))
corr = new_df_for_mcor.corr()
sns.heatmap(corr, cmap='coolwarm_r', annot=True, annot_kws={'size':8})
plt.title('Матрица корреляции', fontsize=16);
```

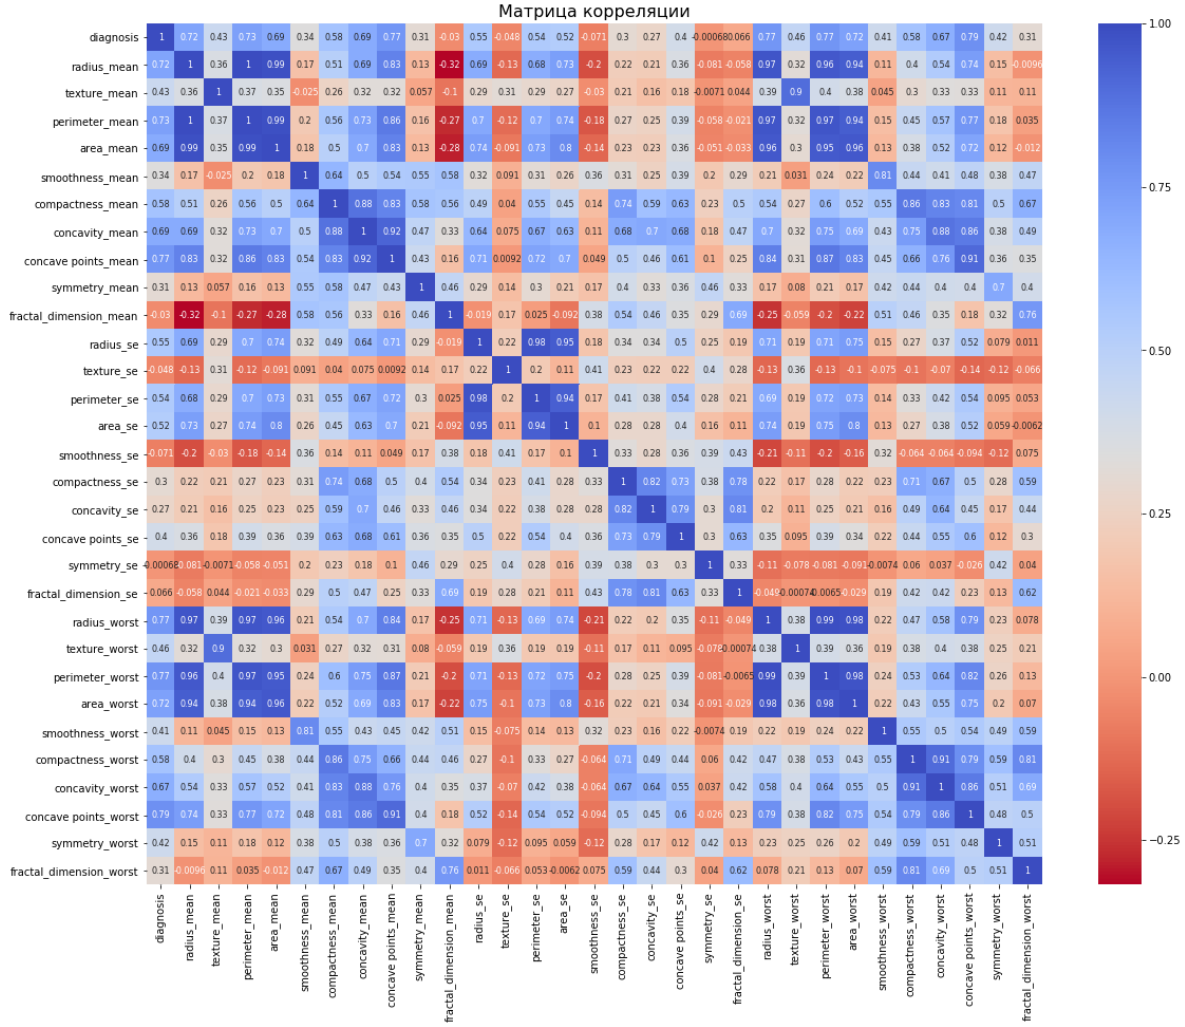

Как видно из матрицы корреляции сильно коррелируют:

- с радиусом - переметр и полощадь (коэффициенты 1,0 и 0,99 соответстенно),
- с параметром P^2 / S - 1 - вес и количество вогнутых частей (коэффициенты 0,88 и 0,84 соответственно),
- с количеством вогнутых частей - вес вогнутых частей (коэффициент 0,92). Для наглядности построим на эти зависимости ближе.

In [15]:

```
def sub_scatter(x, y):
    plt.scatter(x, y)
    z = np.polyfit(x, y, 1)
    p = np.poly1d(z)
    plt.plot(x,p(x),"k-")


print("Зависимости средних значений:")
plt.subplots(figsize=(12,6))
plt.subplot(121)
sub_scatter(new_df_for_mcor['radius_mean'], new_df_for_mcor['perimeter_mean'])
plt.title('Зависимость периметра от радиуса', fontsize=14)

plt.subplot(122)
sub_scatter(new_df_for_mcor['radius_mean'], new_df_for_mcor['area_mean'] / new_df_for_mcor[
plt.title('Зависимость отношения площадь/радиус от радиуса', fontsize=14)


plt.show()
```

```
Зависимости средних значений:
```

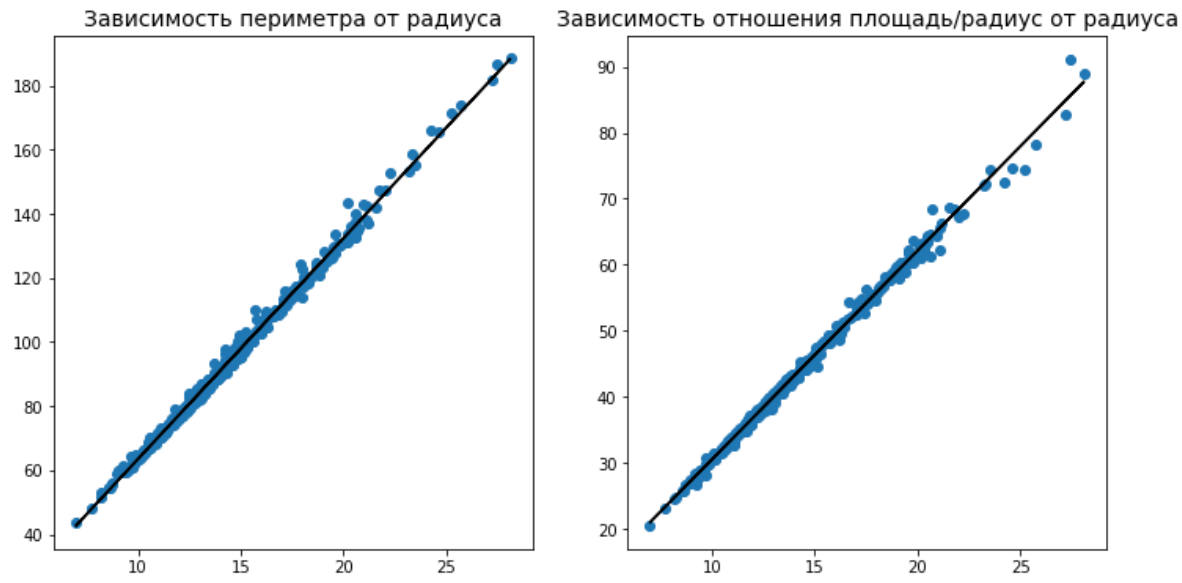

In [16]:

```
print("Зависимости средних значений:")

plt.subplots(figsize=(18,5))
plt.subplot(131)
sub_scatter(new_df_for_mcor['compactness_mean'], new_df_for_mcor['concavity_mean'])
plt.title('Зависимость веса вогнутых \n частей контура от параметра P**2 / S - 1', fontsize

plt.subplot(132)
sub_scatter(new_df_for_mcor['compactness_mean'], new_df_for_mcor['concave points_mean'])
plt.title('Зависимость количества вогнутых \n честей контура от параметра P**2 / S - 1', fo

plt.subplot(133)
sub_scatter(new_df_for_mcor['concave points_mean'], new_df_for_mcor['concavity_mean'])
plt.title('Зависимость веса вогнутых \n честей контура от их количества', fontsize=14)

plt.show()
```

```
Зависимости средних значений:
```

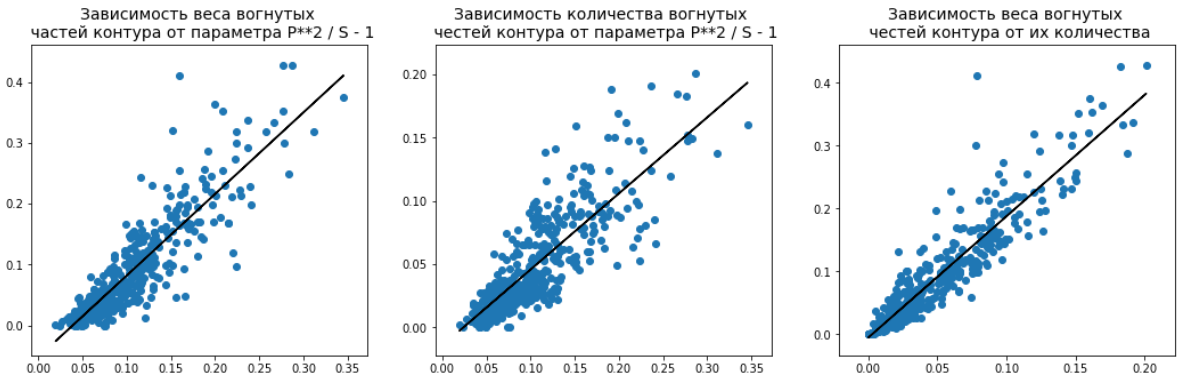

In [17]:

```
# Удалим сильно коррелирующие признаки из df, т.к. они не несут полезной информации
# а так же удалим соответствующие значения из column_names urus_titles
columns = ['perimeter_mean', 'area_mean', 'concavity_mean', 'concave points_mean', 'perimet
           'concave points_se', 'perimeter_worst', 'area_worst', 'concavity_worst', 'conc
new_df_for_mcor.drop(columns, inplace=True, axis=1)

del_col = [3, 4, 7, 8, 13, 14, 17, 18, 23, 24, 27, 28]
column_names = np.delete(column_names, del_col).tolist()
rus_titles = np.delete(rus_titles, del_col).tolist()
```

In [18]:

```
# Все нормально?
i = 0
while i < len(column_names):
    print(i, column_names[i], " - ", rus_titles[i])
    i += 1

df.head()
```

```
0 diagnosis  -  Диагноз
1 radius_mean  -  Средний радиус
2 texture_mean  -  Среднее значение текстуры
3 smoothness_mean  -  Среднее значение гладкости
4 compactness_mean  -  Среднее значение параметра
 P**2 / S - 1
5 symmetry_mean  -  Среднее значение симметрии
6 fractal_dimension_mean  -  Средняя фрактальная размерность
 пограничной линии
7 radius_se  -  СКО радиуса
8 texture_se  -  СКО значения текстуры
9 smoothness_se  -  СКО значения гладкости
10 compactness_se  -  СКО значения параметра
 P^2/S - 1
11 symmetry_se  -  СКО значения симметрии
12 fractal_dimension_se  -  СКО фрактальной размерности
 пограничной линии
13 radius_worst  -  Наибольший радиус
14 texture_worst  -  Наибольшее значение текстуры
15 smoothness_worst  -  Наибольшее значение гладкости
16 compactness_worst  -  Наибольшее значение параметра
 P^2/S - 1
17 symmetry_worst  -  Наибольшее значение симметрии
18 fractal_dimension_worst  -  Наибольшая фрактальная
 размерность пограничной линии
```

Out[18]:

	diagnosis	radius_mean	texture_mean	perimeter_mean	area_mean	smoothness_mean	com
0	1	17.99	10.38	122.80	1001.0	0.11840	
1	1	20.57	17.77	132.90	1326.0	0.08474	
2	1	19.69	21.25	130.00	1203.0	0.10960	
3	1	11.42	20.38	77.58	386.1	0.14250	
4	1	20.29	14.34	135.10	1297.0	0.10030	

5 rows × 31 columns

In [19]:

```
# Построим матрицу корреляции без сильно коррелирующих признаков
f = plt.figure(figsize=(19, 15))
corr = new_df_for_mcor.corr()
sns.heatmap(corr, cmap='coolwarm_r', annot=True, annot_kws={'size':11})
plt.title('Матрица корреляции', fontsize=16);
```

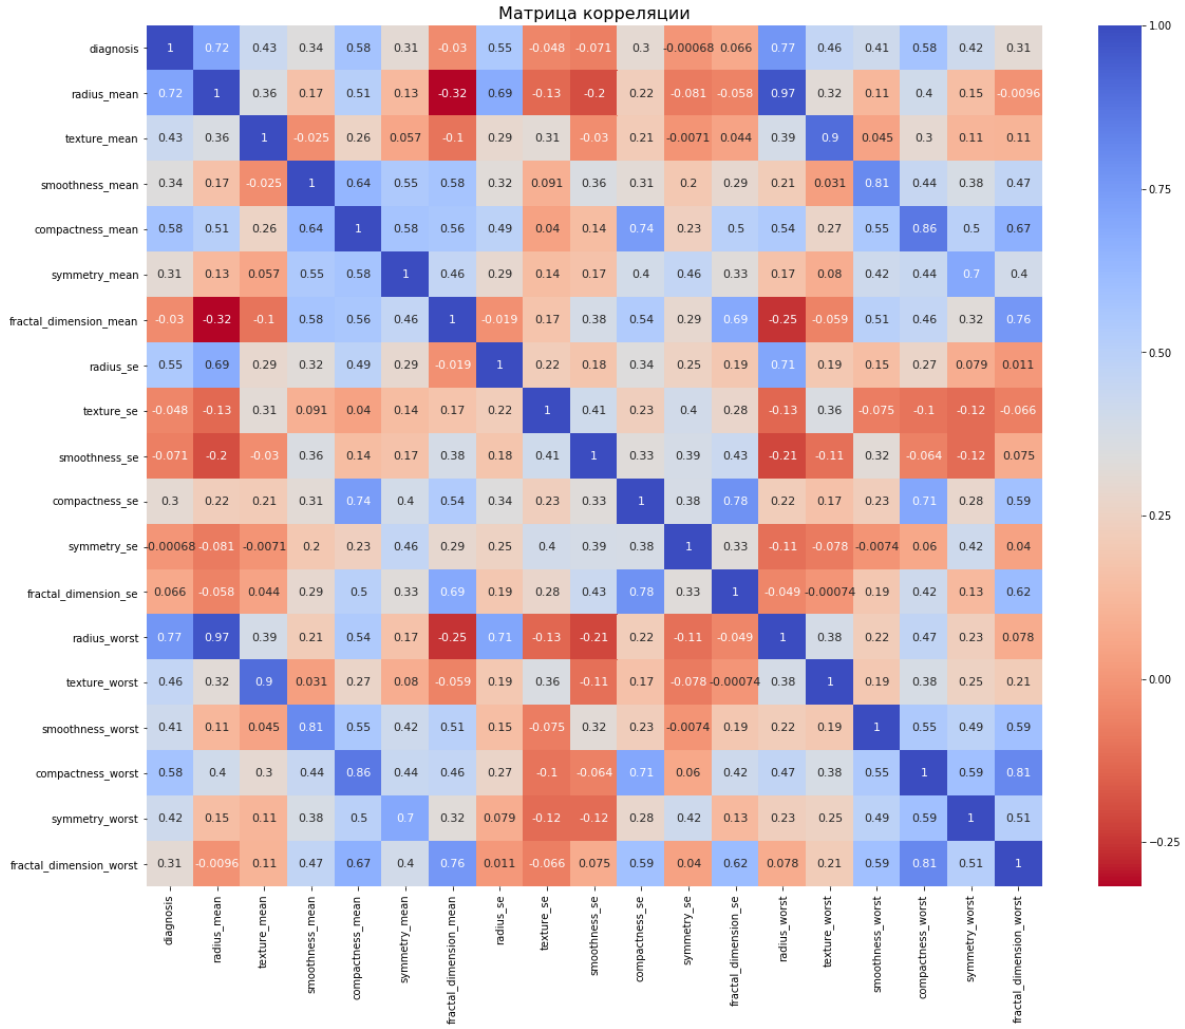

In [20]:

```
# Теперь удалим те же столбцы из исходного набора данных, и дальше будем работать с ним
df.drop(columns, inplace=True, axis=1)

df.head()
```

Out[20]:

	diagnosis	radius_mean	texture_mean	smoothness_mean	compactness_mean	symmetry_me
0	1	17.99	10.38	0.11840	0.27760	0.2
1	1	20.57	17.77	0.08474	0.07864	0.1
2	1	19.69	21.25	0.10960	0.15990	0.2
3	1	11.42	20.38	0.14250	0.28390	0.2
4	1	20.29	14.34	0.10030	0.13280	0.1

Предобработка

Масштабирование

Сначала данные необходимо масштабировать, потом создать набор данных, таким образом чтобы иметь равное количество случаев со злокачественными и доброкачественными опухолями, для того, что бы алгоритмамы лучше работали.

In [21]:

```
from sklearn.preprocessing import StandardScaler, RobustScaler

# в StandardScaler для масштабирования используется среднее значение и дисперсия
# в RobustScaler для масштабирования используется медиана и квартили (по умолчанию 25 и 75)
# RobustScaler менее подвержен выбросам.

std_scaler = StandardScaler()
rob_scaler = RobustScaler()

#сохраняем отдельно столбец с диагнозами
cl = df['diagnosis']

#масштабируем всю таблицу
scalers = {}
for i in range(df.shape[1]):
    scalers[i] = rob_scaler
    df[:] = scalers[i].fit_transform(df[:])

#возвращаем обратно значения диагнозов
df['diagnosis'] = cl
```

In [22]:

```
# все нормально?
df.head()
```

Out[22]:

	diagnosis	radius_mean	texture_mean	smoothness_mean	compactness_mean	symmetry_me
0	1	1.132353	-1.502664	1.190174	2.824832	1.855(
1	1	1.764706	-0.190053	-0.587956	-0.213653	0.059
2	1	1.549020	0.428064	0.725304	1.027337	0.819
3	1	-0.477941	0.273535	2.463286	2.921045	2.381
4	1	1.696078	-0.799290	0.234020	0.613470	0.050

In [23]:

```
# все нормально?
df.describe()
```

Out[23]:

	diagnosis	radius_mean	texture_mean	smoothness_mean	compactness_mean	symmet
count	569.000000	569.000000	569.000000	569.000000	569.000000	56
mean	0.372583	0.185611	0.079867	0.025900	0.178848	
std	0.483918	0.863737	0.763950	0.742954	0.806548	
min	0.000000	-1.565931	-1.621670	-2.284205	-1.118662	-:
25%	0.000000	-0.409314	-0.474245	-0.501849	-0.423183	-(
50%	0.000000	0.000000	0.000000	0.000000	0.000000	
75%	1.000000	0.590686	0.525755	0.498151	0.576817	
max	1.000000	3.612745	3.630551	3.567353	3.860263	

In [24]:

```
# Как мы уже выяснили перед построением матриц корреляции - распределение данных по классам
# Посчитам количество диагнозов, относящихся к разным классам
df['diagnosis'].value_counts()
```

Out[24]:

```
0    357
1    212
Name: diagnosis, dtype: int64
```

Разделение исходного набора

Прежде чем перейти к сэмплированию данных необходимо разделить исходный набор для того, что бы можно было осуществить тестирование. Несмотря на то, что данные будут разделены при реализации методов сэмплирования (UnderSampling или OverSampling), необходимо осуществить **тестированое**

модели на исходном тестовом наборе, а не только на наборе полученном после сэмплирования.

In [25]:

```
from sklearn.model_selection import train_test_split
from sklearn.model_selection import StratifiedShuffleSplit

print('Диагностика опухоли молочной железы:')
print('доброкачественная опухоль обнаружена у ',
      round(df['diagnosis'].value_counts()[0]/len(df) * 100,2), '% диагностированных;')
print('злокачественная опухоль обнаружена у',
      round(df['diagnosis'].value_counts()[1]/len(df) * 100,2), '% диагностированных.')

X = df.drop('diagnosis', axis=1)
y = df['diagnosis']

# StratifiedKFold - стратегия разбиения набора данных в scikit-learn,
# n_splits - на какое кол-во расщепление, random_state - начальное значение генератора случ
sss = StratifiedKFold(n_splits=5, random_state=None, shuffle=False)

for train_index, test_index in sss.split(X, y):
#    print("Train:", train_index, "Test:", test_index)
    original_Xtrain, original_Xtest = X.iloc[train_index], X.iloc[test_index]
    original_ytrain, original_ytest = y.iloc[train_index], y.iloc[test_index]

# Мы уже имеем X_train и y_train для undersample-набора данных, поэтому я использую оригина
# чтобы различать и не перезаписывать эти переменные.
# original_Xtrain, original_Xtest, original_ytrain, original_ytest = train_test_split(X, y,

# Проверим Распределение меток


# Превратить в массив
original_Xtrain = original_Xtrain.values
original_Xtest = original_Xtest.values
original_ytrain = original_ytrain.values
original_ytest = original_ytest.values

# Посмотрим одинаково ли распределены метки на тренировочном и тестовом наборах
train_unique_label, train_counts_label = np.unique(original_ytrain, return_counts=True)
test_unique_label, test_counts_label = np.unique(original_ytest, return_counts=True)
print('-' * 100)

print('Доли классов в распределениях: \n')
print("Train:", train_counts_label/len(original_ytrain))
print("Test: ", test_counts_label/len(original_ytest))
```

```
Диагностика опухоли молочной железы:
доброкачественная опухоль обнаружена у  62.74 % диагностированных;
злокачественная опухоль обнаружена у 37.26 % диагностированных.
----------------------------------------------------------------------------------------
------------------------
Доли классов в распределениях:

Train: [0.62719298 0.37280702]
Test:  [0.62831858 0.37168142]
```

Создание уменьшенного набора данных (Random Under-Sampling)

Метод *"Random Under Sampling"* заключается в удалении данных, с целью получения **сбалансированного набора** . После удаления "лишних" данных, полученный набор перемешивается. Это делается для того, чтобы увидеть, могут ли наши модели воспроизводить определенную точность каждый раз, когда мы запускаем этот скрипт.

Примечание: Основная проблема, связанная с «Random Under-Sampling», заключается в риске того, что наши классификационные модели будут работать не так точно, как хотелось бы, поскольку существует **потеря информации** .

In [26]:

```
# Т.к. количества диагнозов доброкачественных и злокачественных опухолей отличается,
# нам надо выровнить их для нормального распределения классов.

# Перемешаем данные перед созданием подвыборок

df = df.sample(frac=1)

# M = malignant (злокачественная), B = benign (доброкачественная)
# количество строк для класса злокачественных опухолей - 212.
malignant_df = df.loc[df['diagnosis'] == 1]
benign_df = df.loc[df['diagnosis'] == 0][:212]

# объединение malignant_df и benign_df
normal_distributed_df = pd.concat([malignant_df, benign_df])

# Перемешиваем строки в наборе данных
new_df = normal_distributed_df.sample(frac=1, random_state=42).reset_index(drop=True)

new_df.head()
```

Out[26]:

	diagnosis	radius_mean	texture_mean	smoothness_mean	compactness_mean	symmetry_me
0	1	0.512255	-1.234458	1.575806	0.960141	0.5147
1	0	-0.507353	-0.115453	0.002641	0.608888	0.7751
2	1	0.473039	1.142096	0.651347	1.177001	0.3964
3	0	0.311275	-0.353464	-0.499736	-0.391723	-1.1331
4	0	0.323529	-0.863233	0.381933	1.389279	0.8698

Равномерное распределение

Теперь, набор данных сбалансирован.

In [27]:

```
print('Распределение классов в подвыборке данных')
print(new_df['diagnosis'].value_counts()/len(new_df))

sns.countplot('diagnosis', data=new_df, palette=colors)
plt.title('Равномерное распределение классов', fontsize=14)
plt.show()
```

```
Распределение классов в подвыборке данных
1    0.5
0    0.5
Name: diagnosis, dtype: float64
```

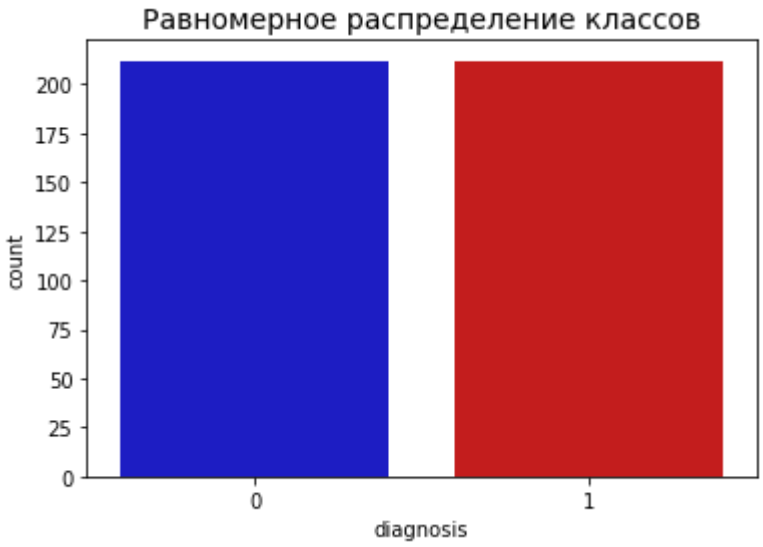

In [28]:

```
# Количество данных отнясящихся к классам:
new_df['diagnosis'].value_counts()
```

Out[28]:

```
1    212
0    212
Name: diagnosis, dtype: int64
```

Обнаружение аномалий

Для обнаружения аномалий рассмотрим более подробно распределения признаков: построим гистограммы и "ящики с усами" для каждого признака. На этом этапе важно не удалить лишнее. **(сейчас удаление выбросов закомечено, т.к. их удаление ничего хорошего не дает)**

In [29]:

```
# build_hist - функция построения гистограмм по классам

# входные параметры:
# df - набор данных, по которым будут строиться гистограммы
# col_names - массив с названиями столбцов по которым будут строиться гистограммы
# param - параметр для структуры, 22 - значит картинка 2x2 т.е. из 4 гистограмм, 42 - значи
# param должно соотвествовать длине массива col_names

def build_hist(df, col_names, titles, param):
    # количество строк на картинке
    y = param // 10
    # количество столбцов на картинке
    x = param % 10
    # width - ширина картинки
    width = 16
    length = width * y / x

    plt.subplots(figsize=(width, length))
    plt.subplots_adjust(wspace=0.3, hspace=0.3)

    num = len(col_names)
    p = param * 10
    i = 1
    while i <= num:
        plt.subplot(p+i)
        x1 = new_df[new_df['diagnosis'] == 0][col_names[i-1]]
        x2 = new_df[new_df['diagnosis'] == 1][col_names[i-1]]
        x1.name, x2.name = 'Д-кач.', 'З-кач.'

        x1.hist(alpha=0.3, weights=[1./len(x1)]*len(x1), color='b')
        x2.hist(alpha=0.3, weights=[1./len(x2)]*len(x2), color='r')
        plt.axvline(x1.mean(), color='b', alpha=0.8, linestyle='dashed')
        plt.axvline(x2.mean(), color='r', alpha=0.8, linestyle='dashed')
        plt.title(titles[i-1], fontsize=14)

        #plt.xlabel(col_names[i-1], fontsize=12)
        plt.ylabel(None)
        #plt.ylabel("Частота", fontsize=12)
        #plt.xticks(fontsize=10)
        #plt.yticks(fontsize=10)
        if i == x:
            plt.legend([x1.name, x2.name])
        i += 1
```

In [30]:

```
build_hist(new_df, column_names[1:7], rus_titles[1:7], 23)
```

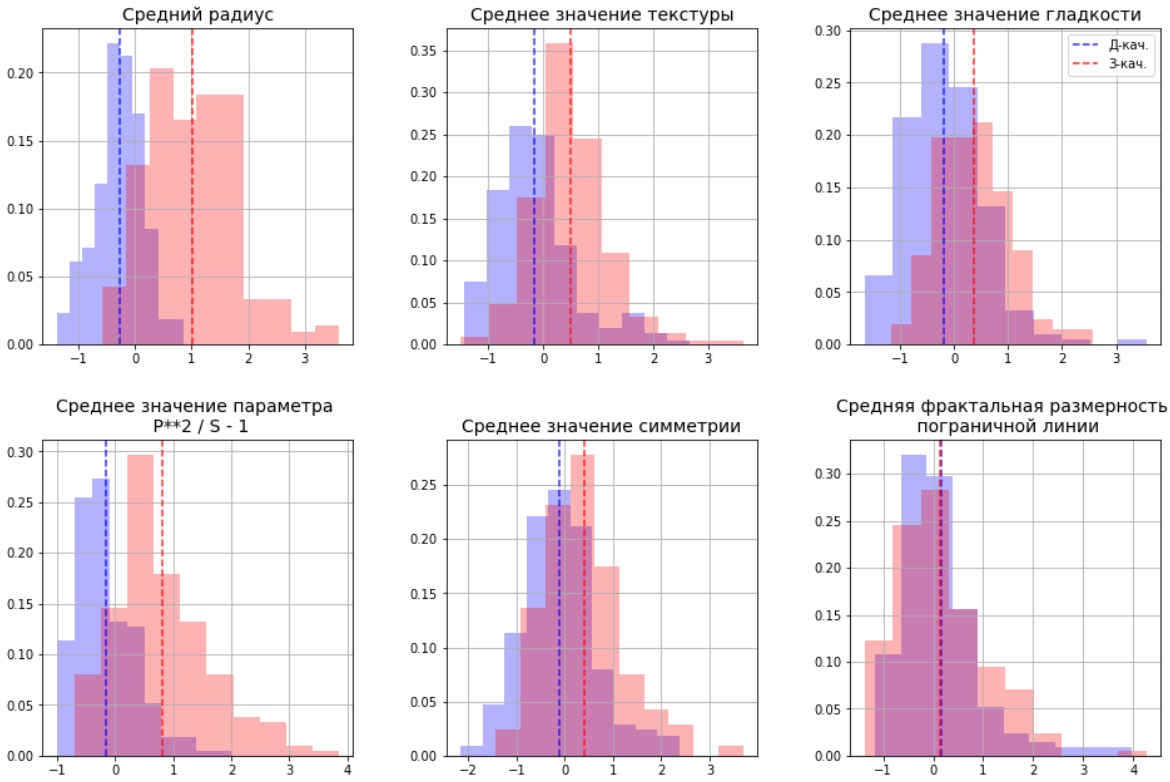

In [31]:

```
build_hist(new_df, column_names[7:13], rus_titles[7:13], 23)
```

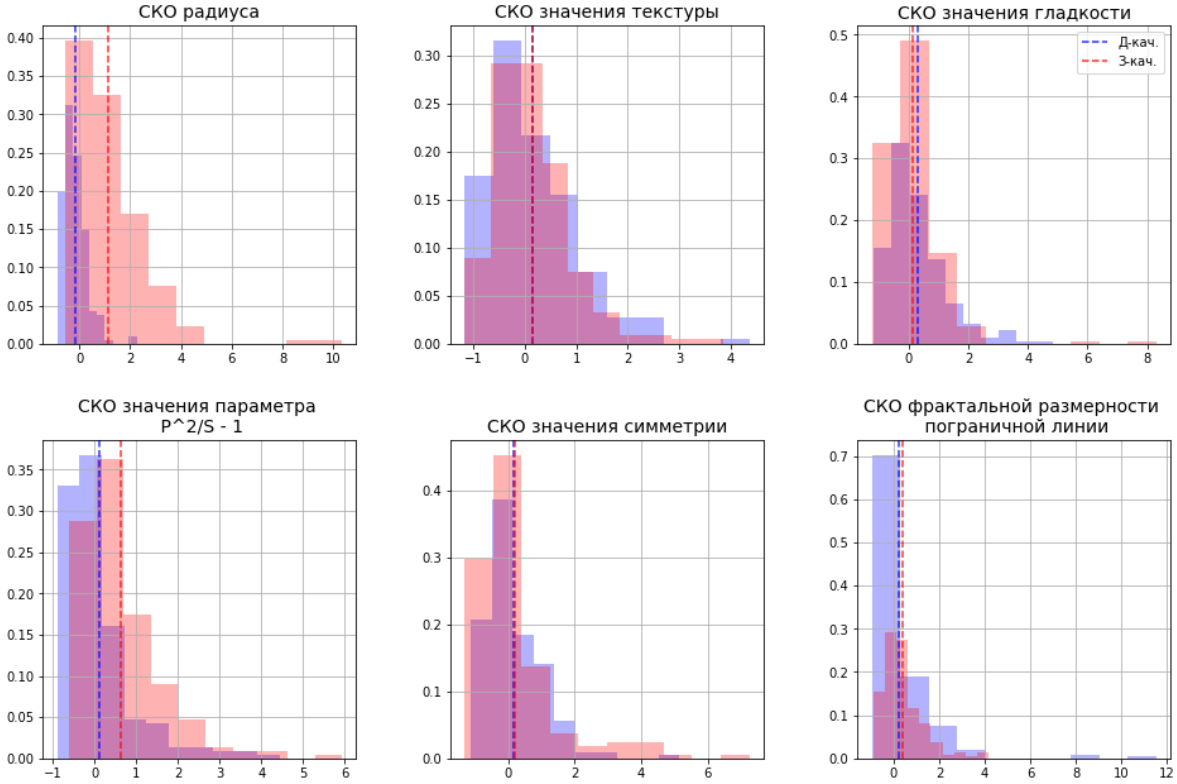

In [32]:

```
build_hist(new_df, column_names[13:19], rus_titles[13:19], 23)
```

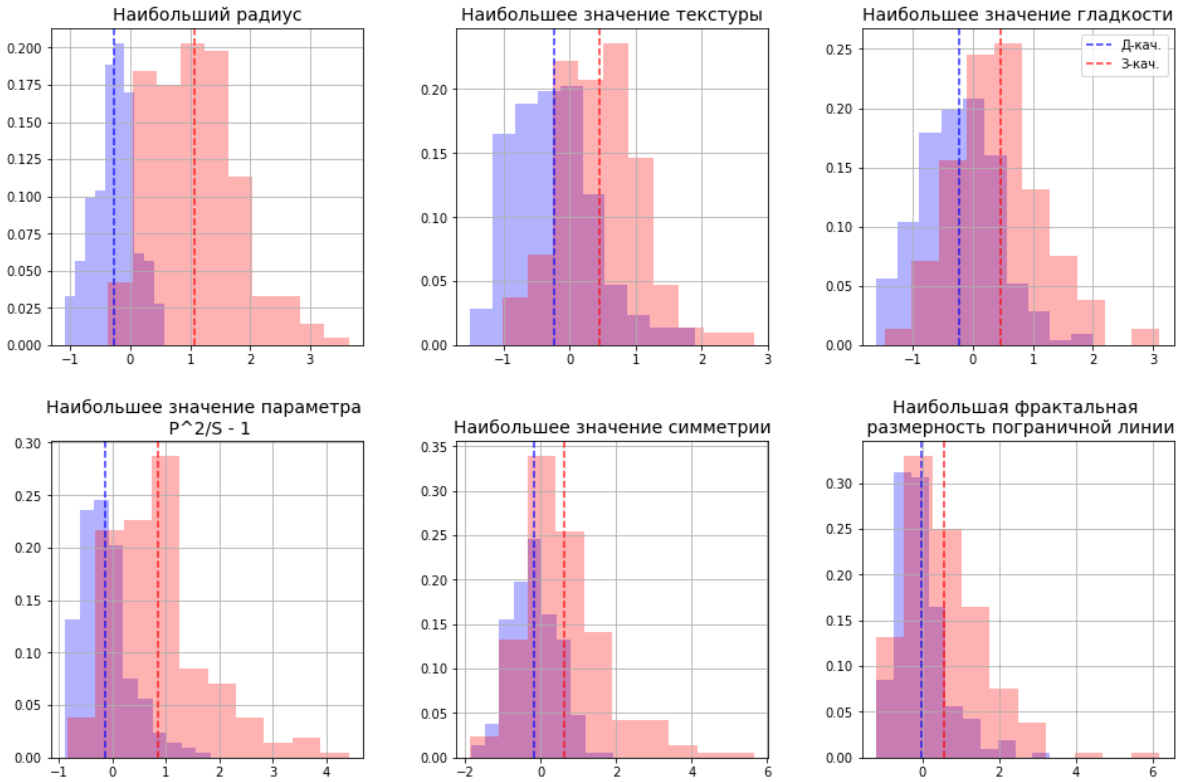

In [33]:

```
data = pd.melt(new_df,id_vars="diagnosis",
                    var_name="Признаки",
                    value_name='Значение')

plt.figure(figsize=(16,10))
sns.boxplot(x="Признаки", y="Значение", hue="diagnosis", data=data, palette=colors)
plt.xticks(rotation=90)

plt.show()
```

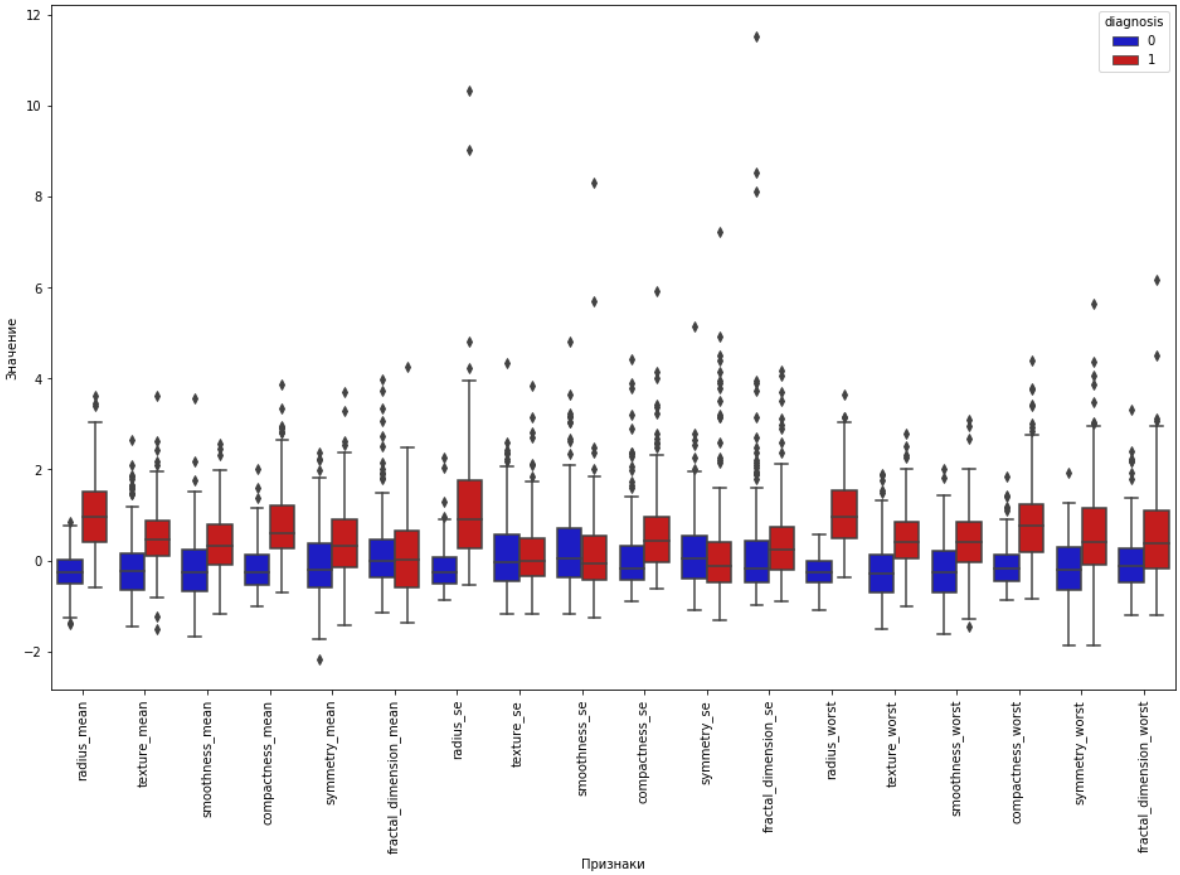

In [34]:

```
# по каким столбцам будет удаление выбросов?
# num - массив с номерами столбцов по которым будем избавляться от выбросов

num = [13, 17]
```

```
0 diagnosis  -  Диагноз
1 radius_mean  -  Средний радиус
2 texture_mean  -  Среднее значение текстуры
3 smoothness_mean  -  Среднее значение гладкости
4 compactness_mean  -  Среднее значение параметра P**2 / S - 1
5 symmetry_mean  -  Среднее значение симметрии
6 fractal_dimension_mean  -  Средняя фрактальная размерность пограничной линии
7 radius_se  -  СКО радиуса
8 texture_se  -  СКО значения текстуры
9 smoothness_se  -  СКО значения гладкости
10 compactness_se  -  СКО значения параметра P^2/S - 1
11 symmetry_se  -  СКО значения симметрии
12 fractal_dimension_se  -  СКО фрактальной размерности пограничной линии
13 radius_worst  -  Наибольший радиус
14 texture_worst  -  Наибольшее значение текстуры
15 smoothness_worst  -  Наибольшее значение гладкости
16 compactness_worst  -  Наибольшее значение параметра P^2/S - 1
17 symmetry_worst  -  Наибольшее значение симметрии
18 fractal_dimension_worst  -  Наибольшая фрактальная размерность пограничной линии
```

In [35]:

```
# build_hist - функция построения гистограмм по классам
# входные параметры:
# df - набор данных, по которым будут строиться гистограммы
# col_names - массив с названиями столбцов по которым будут строиться гистограммы
# param - параметр для структуры, 22 - значит картинка 2x2 т.е. из 4 гистограмм, 42 - значи
# param должно соотвествовать длине массива col_names

# отображенеи build_boxplots в несколько рядов
def build_boxplots_xx(df, col_names, titles, param):
    # количество строк на картинке
    y = param // 10
    # количество столбцов на картинке
    x = param % 10
    # width - ширина картинки
    width = 16
    length = width * y / x

    f, axes = plt.subplots(nrows=y, ncols=x, figsize=(width, length))
    plt.subplots_adjust(wspace=0.3, hspace=0.3)

    i = j = k = 0
    while i < y:
        j = 0
        while j < x:
            sns.boxplot(x="diagnosis", y=col_names[k], data=df, palette=colors, ax=axes[i,
            axes[i, j].set_title(titles[k])
            k += 1
            j += 1
        i += 1

# отображенеи build_boxplots в один ряд
def build_boxplots_x(df, col_names, titles, param):
    # количество столбцов на картинке
    x = len(col_names)
    width = x*4
    length = 4

    f, axes = plt.subplots(1, x, figsize=(width, length))
    plt.subplots_adjust(wspace=0.3, hspace=0.3)

    i = 0
    while i < x:
        sns.boxplot(x="diagnosis", y=col_names[i], data=df, palette=colors, ax=axes[i])
        axes[i].set_title(titles[i])
        i += 1

# отображенеи build_boxplots
def build_boxplots(df, col_names, titles, param):
    if param >= 10:
        build_boxplots_xx(df, col_names, titles, param)
    else:
        build_boxplots_x(df, col_names, titles, param)
```

In [36]:

```
# num - массив с номерами столбцов по которым будем избавляться от выбросов

# cols_b - список признаков по которым будут строиться boxplots
# title_b - список названий к boxplots

cols_b = list()
title_b = list()

i = 0
while i < len(num):
    cols_b.append(column_names[num[i]])
    title_b.append(rus_titles[num[i]])
    i += 1

print(cols_b)
print(title_b)
```

```
['radius_worst', 'symmetry_worst']
['Наибольший радиус', 'Наибольшее значение симметрии']
```

In [37]:

```
build_boxplots(new_df, cols_b, title_b, 2)
```

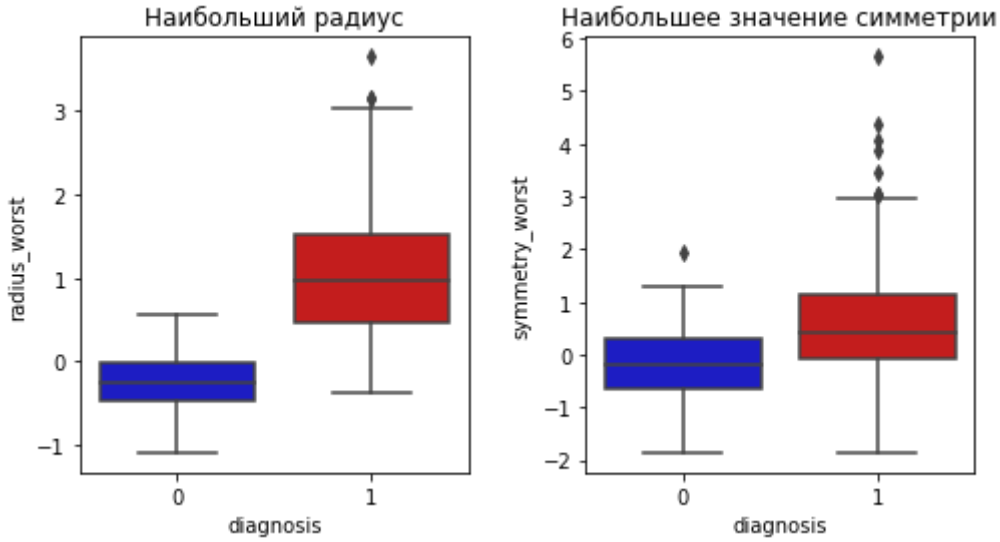

In [38]:

```
# drop_outliers(column_name, d) - функция для удаления выбросов по одному из признаков, при
# df - data frame из которого будут удаляться выбросы,
# column_name - название столбца, d - диагноз (0 - для доброкачественных, 1 - для злокачест

def drop_outliers(data_frame, column_name, d):
    print("Удаление выбросов по", column_name, "для диагноза", d)
    column = data_frame[column_name].loc[data_frame['diagnosis'] == d].values

    # q25, q75 - значения функции V14, соответствующие перцентилям 25 и 75
    q25, q75 = np.percentile(column, 25), np.percentile(column, 75)
    print('Перцентиль 25: {} | Перцентиль 75: {}'.format(q25, q75))

    # column_iqr - интерквартильный интервал (между 1 и 3 квартилями)
    column_iqr = q75 - q25
    print('iqr: {}'.format(column_iqr))

    # column_cut_off - значения, находящиеся на таком расстоянии*1.5 от 1 и 3 кваритлей буд
    column_cut_off = column_iqr * 1.5

    # column_lower, column_upper - нижняя и верхняя границы
    column_lower, column_upper = q25 - column_cut_off, q75 + column_cut_off
    print('Отрезать: {}'.format(column_cut_off))
    print('Нижняя грань: {}'.format(column_lower))
    print('Верхняя грань: {}'.format(column_upper))

    # outliers - выбросы
    outliers = [x for x in column if x < column_lower or x > column_upper]
    print('Количество выбросов: {}'.format(len(outliers)))
    print('Выбросы: {}'.format(outliers))

    # df_dr_out - создаем новый столбец из старого, только без выбросов
    df_dr_out = data_frame.drop(data_frame[(data_frame[column_name] > column_upper) | (data
    print('Количество экземпляров после удаления выбросов: ', len(data_frame))
    print('----' * 30)

    return df_dr_out
```

In [39]:

```
print("Удаление выбросов будет произовдиться по следующим признакам: \n", cols_b)
print("Количество признаков", len(cols_b))
```

```
Удаление выбросов будет произовдиться по следующим признакам:
 ['radius_worst', 'symmetry_worst']
Количество признаков 2
```

In [40]:

```
# удаление выбросов будет производиться по следующим признакам:
print("Количество экземпляров до удаления выбросов: ", len(new_df), "\n")

#new_df_ = drop_outliers(new_df, cols_b[0], 1)
#new_df = drop_outliers(new_df, cols_b[1], 1)

print("После: ", len(new_df), "\n")
```

```
Количество экземпляров до удаления выбросов:  424

После:  424
```

In [41]:

```
colors = ['#B3F9C5', '#f9c5b3']

print("После удаления выбросов:")
build_boxplots(new_df, cols_b, title_b, 2)
```

```
После удаления выбросов:
```

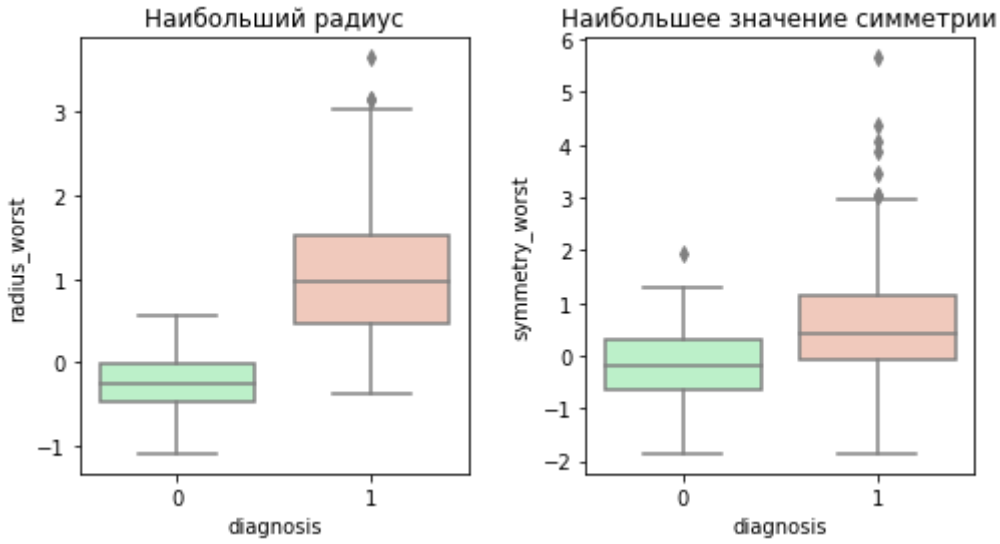

Классификацая

Уменьшение размерности и кластеризация

Рассмотрим три метода, позволяющие сгруппировать классы:

- Метод **t-SNE** - t-distributed Stochastic Neighbor Embedding - стохастическое вложение соседей с t-распределением;
- Метод **PCA** - Principal Component Analysis - метод главных компонент;
- Метод **TruncatedSVD** - Truncated Singular Value Decomposition - усеченное сингулярное разложение.

In [42]:

```
# уменьшение размерности

X = new_df.drop('diagnosis', axis=1)
y = new_df['diagnosis']


# T-SNE реализация
t0 = time.time()
X_reduced_tsne = TSNE(n_components=2, random_state=42).fit_transform(X.values)
t1 = time.time()
print("T-SNE занял {:.2} s".format(t1 - t0))

# PCA реализация
t0 = time.time()
X_reduced_pca = PCA(n_components=2, random_state=42).fit_transform(X.values)
t1 = time.time()
print("PCA занял {:.2} s".format(t1 - t0))

# TruncatedSVD реализация
t0 = time.time()
X_reduced_svd = TruncatedSVD(n_components=2, algorithm='randomized', random_state=42).fit_t
t1 = time.time()
print("Truncated SVD занял {:.2} s".format(t1 - t0))
```

```
T-SNE занял 2.9 s
PCA занял 0.002 s
Truncated SVD занял 0.002 s
```

In [43]:

```
f, (ax1, ax2, ax3) = plt.subplots(1, 3, figsize=(24,6))
# labels = ['Доброкачественная', 'Злокачественная']
f.suptitle('Кластеризация с использованием снижения размерности', fontsize=14)

blue_patch = mpatches.Patch(color=colors[0], label='Доброкачественная')
red_patch = mpatches.Patch(color=colors[1], label='Злокачественная')


# t-SNE scatter plot
ax1.scatter(X_reduced_tsne[:,0], X_reduced_tsne[:,1], c=(y == 0), cmap='coolwarm', label='Д
ax1.scatter(X_reduced_tsne[:,0], X_reduced_tsne[:,1], c=(y == 1), cmap='coolwarm', label='З
ax1.set_title('t-SNE', fontsize=14)
ax1.grid(True)
ax1.legend(handles=[blue_patch, red_patch])


# PCA scatter plot
ax2.scatter(X_reduced_pca[:,0], X_reduced_pca[:,1], c=(y == 0), cmap='coolwarm', label='Доб
ax2.scatter(X_reduced_pca[:,0], X_reduced_pca[:,1], c=(y == 1), cmap='coolwarm', label='Зло
ax2.set_title('PCA', fontsize=14)
ax2.grid(True)
ax2.legend(handles=[blue_patch, red_patch])

# TruncatedSVD scatter plot
ax3.scatter(X_reduced_svd[:,0], X_reduced_svd[:,1], c=(y == 0), cmap='coolwarm', label='Доб
ax3.scatter(X_reduced_svd[:,0], X_reduced_svd[:,1], c=(y == 1), cmap='coolwarm', label='Зло
ax3.set_title('Truncated SVD', fontsize=14)
ax3.grid(True)
ax3.legend(handles=[blue_patch, red_patch])

plt.show()
```

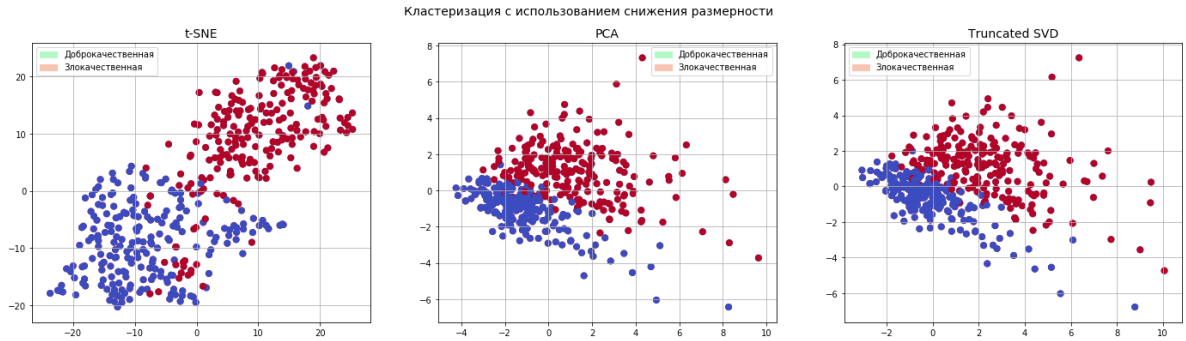

Классификаторы (UnderSampling):

Для того, что бы понять какой классификатор работает лучше нужно обучить и протестировать каждый. Прежде чем начать разделение данных на наборы для обучения и тестирования нужно отделить функции от меток.

In [44]:

```
# Создание подвыборки перед проверкой (склонность к переобучению)
X = new_df.drop('diagnosis', axis=1)
y = new_df['diagnosis']
```

In [45]:

```
# Данные уже масштабированы, нужно разделить на обучающую и тестовую подвыборки
from sklearn.model_selection import train_test_split

# Это используется для подвыбоки
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)
```

In [46]:

```
# Преобразовать значения в массив для алгоритмов классификации
X_train = X_train.values
X_test = X_test.values
y_train = y_train.values
y_test = y_test.values
```

In [47]:

```
# Реализуем простые классификаторы

classifiers = {
    "Логистическая регрессия": LogisticRegression(),
    "К-средних": KNeighborsClassifier(),
    "Опорные вектора": SVC(),
    "Дерево решений": DecisionTreeClassifier()
}
```

In [48]:

```
# наши оценки получают высокую точность даже на проверочном наборе
from sklearn.model_selection import cross_val_score


for key, classifier in classifiers.items():
    classifier.fit(X_train, y_train)
    training_score = cross_val_score(classifier, X_train, y_train, cv=5)
    print("Классификатор", classifier.__class__.__name__, "имеет оценку на тестовом наборе
```

```
Классификатор LogisticRegression имеет оценку на тестовом наборе  95.0 %
Классификатор KNeighborsClassifier имеет оценку на тестовом наборе  95.0 %
Классификатор SVC имеет оценку на тестовом наборе  95.0 %
Классификатор DecisionTreeClassifier имеет оценку на тестовом наборе  91.0 %
```

In [49]:

```
# Будет использоваться GridSearchCV для поиска параметров, дающих наилучшую прогностическую
from sklearn.model_selection import GridSearchCV

# Логистическая регрессия
log_reg_params = {"penalty": ['l1', 'l2'], 'C': [0.001, 0.01, 0.1, 1, 10, 100, 1000]}
grid_log_reg = GridSearchCV(LogisticRegression(), log_reg_params)
grid_log_reg.fit(X_train, y_train)
# Логистическая регрессия лучший вариант
log_reg = grid_log_reg.best_estimator_

# K-средних
knears_params = {"n_neighbors": list(range(2,5,1)), 'algorithm': ['auto', 'ball_tree', 'kd_
grid_knears = GridSearchCV(KNeighborsClassifier(), knears_params)
grid_knears.fit(X_train, y_train)
# K-средних лучший вариант
knears_neighbors = grid_knears.best_estimator_

# SVC
svc_params = {'C': [0.5, 0.7, 0.9, 1], 'kernel': ['rbf', 'poly', 'sigmoid', 'linear']}
grid_svc = GridSearchCV(SVC(), svc_params)
grid_svc.fit(X_train, y_train)
# SVC лучший вариант
svc = grid_svc.best_estimator_

# Дерево решений
tree_params = {"criterion": ["gini", "entropy"], "max_depth": list(range(2,4,1)),
              "min_samples_leaf": list(range(5,7,1))}
grid_tree = GridSearchCV(DecisionTreeClassifier(), tree_params)
grid_tree.fit(X_train, y_train)
# Дерево решений лучший вариант
tree_clf = grid_tree.best_estimator_
```

In [50]:

```
# Случай переобучения

log_reg_score = cross_val_score(log_reg, X_train, y_train, cv=5)
print('Классификатор Логистической регресси имеет оценку на проверочном наборе данных: ',
      round(log_reg_score.mean() * 100, 2).astype(str) + '%')


knears_score = cross_val_score(knears_neighbors, X_train, y_train, cv=5)
print('Классификатор метода К-средних соседей имеет оценку на проверочном наборе данных',
      round(knears_score.mean() * 100, 2).astype(str) + '%')

svc_score = cross_val_score(svc, X_train, y_train, cv=5)
print('Классификатор метода Опорных векторов имеет оценку на проверочном наборе данных',
      round(svc_score.mean() * 100, 2).astype(str) + '%')

tree_score = cross_val_score(tree_clf, X_train, y_train, cv=5)
print('Классификатор Дерева решений имеет оценку на проверочном наборе данных',
      round(tree_score.mean() * 100, 2).astype(str) + '%')
```

```
Классификатор Логистической регресси имеет оценку на проверочном наборе данн
ых:  95.56%
Классификатор метода К-средних соседей имеет оценку на проверочном наборе да
нных 94.99%
Классификатор метода Опорных векторов имеет оценку на проверочном наборе дан
ных 95.28%
Классификатор Дерева решений имеет оценку на проверочном наборе данных 93.4
9%
```

In [51]:

```
# Мы будем создавать подвыборку во время проверки
undersample_X = df.drop('diagnosis', axis=1)
undersample_y = df['diagnosis']

for train_index, test_index in sss.split(undersample_X, undersample_y):
    print("Train:", train_index, "Test:", test_index)
    undersample_Xtrain, undersample_Xtest = undersample_X.iloc[train_index], undersample_X.
    undersample_ytrain, undersample_ytest = undersample_y.iloc[train_index], undersample_y.

undersample_Xtrain = undersample_Xtrain.values
undersample_Xtest = undersample_Xtest.values
undersample_ytrain = undersample_ytrain.values
undersample_ytest = undersample_ytest.values

undersample_accuracy = []
undersample_precision = []
undersample_recall = []
undersample_f1 = []
undersample_auc = []

# Использование техники NearMiss
# Распределение NearMiss (просто чтобы посмотреть, как он распределяет метки, мы не будем и
X_nearmiss, y_nearmiss = NearMiss().fit_sample(undersample_X.values, undersample_y.values)
print('NearMiss Label Distribution: {}'.format(Counter(y_nearmiss)))

# Кросс-валидация правильный путь

for train, test in sss.split(undersample_Xtrain, undersample_ytrain):
    undersample_pipeline = imbalanced_make_pipeline(NearMiss(sampling_strategy='majority'),
    # NearMiss происходит во время перекрестной проверки, не раньше..
    undersample_model = undersample_pipeline.fit(undersample_Xtrain[train], undersample_ytr
    undersample_prediction = undersample_model.predict(undersample_Xtrain[test])

    undersample_accuracy.append(undersample_pipeline.score(original_Xtrain[test], original_
    undersample_precision.append(precision_score(original_ytrain[test], undersample_predict
    undersample_recall.append(recall_score(original_ytrain[test], undersample_prediction))
    undersample_f1.append(f1_score(original_ytrain[test], undersample_prediction))
    undersample_auc.append(roc_auc_score(original_ytrain[test], undersample_prediction))
```

```
6  17
  18  19  20  21  22  23  24  25  26  27  28  29  30  31  32  33  34  35
  36  37  38  39  40  41  42  43  44  45  46  47  48  49  50  51  52  53
  54  55  56  57  58  59  60  61  62  63  64  65  66  67  68  69  70  71

  72  73  74  75  76  77  78  79  80  81  82  83  84  85  86  87  88  89
  90  91  92  93  94  95  96  97  98  99 100 101 102 103 104 105 106 107
 108 109 110 111 112 113 114 115 116 117 118 119 120 121 122 123 124 125
 126 127 128 129 130 131 132 133 134 135 136 137 138 139 140 141 142 143
 144 145 146 147 148 149 150 151 152 153 154 155 156 157 158 159 160 161
 162 163 164 165 166 167 168 169 170 171 172 173 174 175 176 177 178 179
 180 181 182 183 184 185 186 187 188 189 190 191 192 193 194 195 196 197
 198 199 200 201 202 203 204 205 206 207 208 209 210 211 212 213 214 215
 216 217 218 219 220 221 222 223 224 225 226 227 228 229 230 231 232 233
 234 235 236 237 238 239 240 241 242 243 244 245 246 247 248 249 250 251
 252 253 254 255 256 257 258 259 260 261 262 263 264 265 266 267 268 269
 270 271 272 273 274 275 276 277 278 279 280 281 282 283 284 285 286 287
 288 289 290 291 292 293 294 295 296 297 298 299 300 301 302 303 304 305
 306 307 308 309 310 311 312 313 314 315 316 317 318 319 320 321 322 323
 324 325 326 327 328 329 330 331 332 333 334 335 336 337 338 339 340 341
```

Кривые обучения

- Чем **больше разница** между оценкой при обучении и оценкой при кросс-валидации, тем выше вероятность того, что модель **переобучаена (высокое расхождение)** .
- Если оценка низкая как на обучающем, так и на проверочном наборах, то модель **недостаточно подходит (высокий уклон)**

In [52]:

```
# Кривые обучения
from sklearn.model_selection import ShuffleSplit
from sklearn.model_selection import learning_curve

def plot_learning_curve(estimator1, estimator2, estimator3, estimator4, X, y, ylim=None, cv
                        n_jobs=1, train_sizes=np.linspace(.1, 1.0, 5)):
    f, ((ax1, ax2), (ax3, ax4)) = plt.subplots(2,2, figsize=(20,14), sharey=True)
    if ylim is not None:
        plt.ylim(*ylim)


    # Логистическая регрессия
    train_sizes, train_scores, test_scores = learning_curve(
        estimator1, X, y, cv=cv, n_jobs=n_jobs, train_sizes=train_sizes)
    train_scores_mean = np.mean(train_scores, axis=1)
    train_scores_std = np.std(train_scores, axis=1)
    test_scores_mean = np.mean(test_scores, axis=1)
    test_scores_std = np.std(test_scores, axis=1)
    ax1.fill_between(train_sizes, train_scores_mean - train_scores_std,
                     train_scores_mean + train_scores_std, alpha=0.1,
                     color="#ff9124")
    ax1.fill_between(train_sizes, test_scores_mean - test_scores_std,
                     test_scores_mean + test_scores_std, alpha=0.1, color="#2492ff")
    ax1.plot(train_sizes, train_scores_mean, 'o-', color="#ff9124",
             label="Обучающий набор")
    ax1.plot(train_sizes, test_scores_mean, 'o-', color="#2492ff",
             label="Проверочный набор")
    ax1.set_title("Метод: Логистическая регрессия", fontsize=16)
    ax1.set_xlabel('Длительность обчения (m)')
    ax1.set_ylabel('Точность')
    ax1.grid(True)
    ax1.legend(loc="best")


    # K-средних
    train_sizes, train_scores, test_scores = learning_curve(
        estimator2, X, y, cv=cv, n_jobs=n_jobs, train_sizes=train_sizes)
    train_scores_mean = np.mean(train_scores, axis=1)
    train_scores_std = np.std(train_scores, axis=1)
    test_scores_mean = np.mean(test_scores, axis=1)
    test_scores_std = np.std(test_scores, axis=1)
    ax2.fill_between(train_sizes, train_scores_mean - train_scores_std,
                     train_scores_mean + train_scores_std, alpha=0.1,
                     color="#ff9124")
    ax2.fill_between(train_sizes, test_scores_mean - test_scores_std,
                     test_scores_mean + test_scores_std, alpha=0.1, color="#2492ff")
    ax2.plot(train_sizes, train_scores_mean, 'o-', color="#ff9124",
             label="Обучающий набор")
    ax2.plot(train_sizes, test_scores_mean, 'o-', color="#2492ff",
             label="Проверочный набор")
    ax2.set_title("Метод: K-средних соседей", fontsize=16)
    ax2.set_xlabel('Длительность обчения (m)')
    ax2.set_ylabel('Точность')
    ax2.grid(True)
    ax2.legend(loc="best")


    # Опорные вектора
    train_sizes, train_scores, test_scores = learning_curve(
```

```
        estimator3, X, y, cv=cv, n_jobs=n_jobs, train_sizes=train_sizes)
    train_scores_mean = np.mean(train_scores, axis=1)
    train_scores_std = np.std(train_scores, axis=1)
    test_scores_mean = np.mean(test_scores, axis=1)
    test_scores_std = np.std(test_scores, axis=1)
    ax3.fill_between(train_sizes, train_scores_mean - train_scores_std,
                     train_scores_mean + train_scores_std, alpha=0.1,
                     color="#ff9124")
    ax3.fill_between(train_sizes, test_scores_mean - test_scores_std,
                     test_scores_mean + test_scores_std, alpha=0.1, color="#2492ff")
    ax3.plot(train_sizes, train_scores_mean, 'o-', color="#ff9124",
             label="Обучающий набор")
    ax3.plot(train_sizes, test_scores_mean, 'o-', color="#2492ff",
             label="Проверочный набор")
    ax3.set_title("Метод: Опорные вектора", fontsize=16)
    ax3.set_xlabel('Длительность обчения (m)')
    ax3.set_ylabel('Точность')
    ax3.grid(True)
    ax3.legend(loc="best")


    # Дерово решений
    train_sizes, train_scores, test_scores = learning_curve(
        estimator4, X, y, cv=cv, n_jobs=n_jobs, train_sizes=train_sizes)
    train_scores_mean = np.mean(train_scores, axis=1)
    train_scores_std = np.std(train_scores, axis=1)
    test_scores_mean = np.mean(test_scores, axis=1)
    test_scores_std = np.std(test_scores, axis=1)
    ax4.fill_between(train_sizes, train_scores_mean - train_scores_std,
                     train_scores_mean + train_scores_std, alpha=0.1,
                     color="#ff9124")
    ax4.fill_between(train_sizes, test_scores_mean - test_scores_std,
                     test_scores_mean + test_scores_std, alpha=0.1, color="#2492ff")
    ax4.plot(train_sizes, train_scores_mean, 'o-', color="#ff9124",
             label="Обучающий набор")
    ax4.plot(train_sizes, test_scores_mean, 'o-', color="#2492ff",
             label="Проверочный набор")
    ax4.set_title("Метод: Дерево решений", fontsize=16)
    ax4.set_xlabel('Длительность обчения (m)')
    ax4.set_ylabel('Точность')
    ax4.grid(True)
    ax4.legend(loc="best")
    return plt
```

In [53]:

```
cv = ShuffleSplit(n_splits=100, test_size=0.2, random_state=42)
print("Кривые обучения классификаторов разных методов:")
plot_learning_curve(log_reg, knears_neighbors, svc, tree_clf, X_train, y_train, (0.87, 1.01
plt.show()
```

```
Кривые обучения классификаторов разных методов:
```

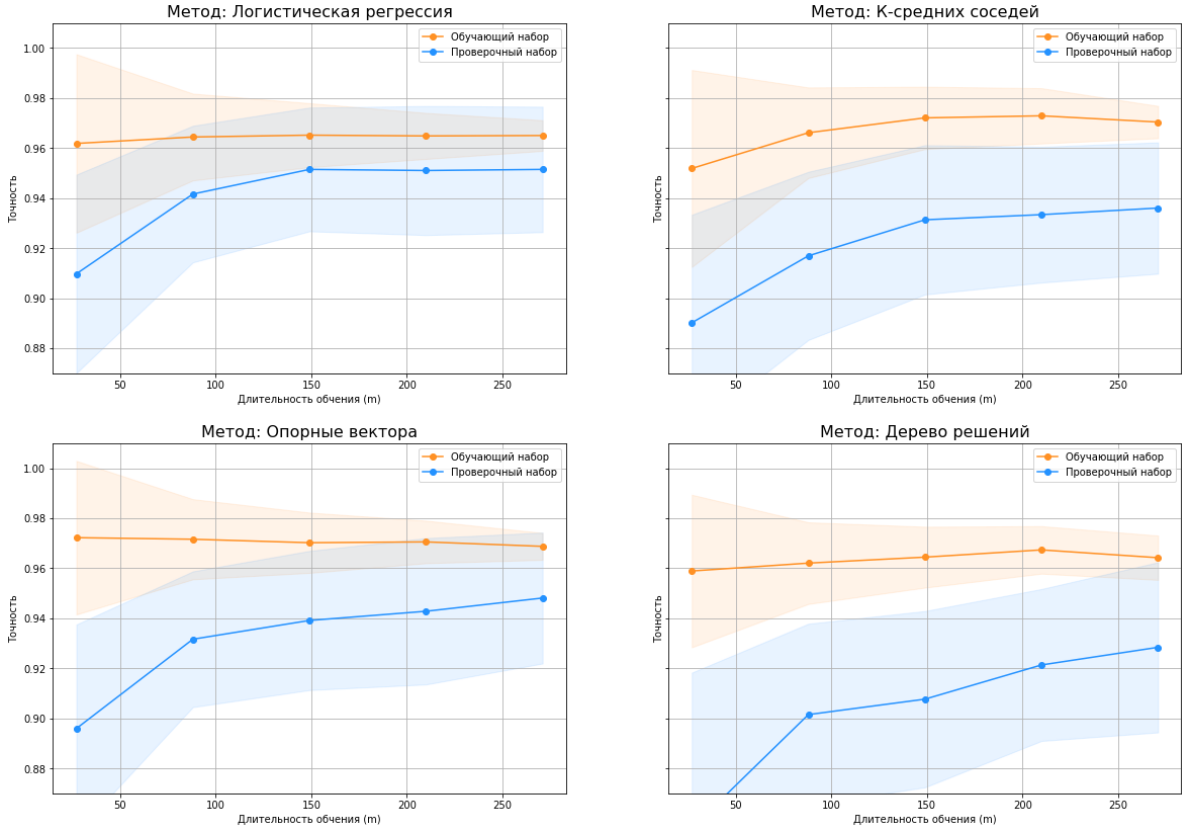

In [54]:

```
from sklearn.metrics import roc_curve
from sklearn.model_selection import cross_val_predict
# Создать подвыборку со всеми оценками и именами классификаторов

log_reg_pred = cross_val_predict(log_reg, X_train, y_train, cv=5,
                                 method="decision_function")

knears_pred = cross_val_predict(knears_neighbors, X_train, y_train, cv=5)

svc_pred = cross_val_predict(svc, X_train, y_train, cv=5,
                             method="decision_function")

tree_pred = cross_val_predict(tree_clf, X_train, y_train, cv=5)
```

In [55]:

```
from sklearn.metrics import roc_auc_score

print('Логистическая регрессия: ', roc_auc_score(y_train, log_reg_pred))
print('K-средних: ', roc_auc_score(y_train, knears_pred))
print('Опорные вектора: ', roc_auc_score(y_train, svc_pred))
print('Дерево решений: ', roc_auc_score(y_train, tree_pred))
```

```
Логистическая регрессия:  0.9901489835700361
K-средних:  0.9500313283208021
Опорные вектора:  0.9912280701754386
Дерево решений:  0.9324352548036758
```

ROC-кривые

Термины:

- **Правильные позитивные оценки (True Positives Rate):** правильно классифицированные злокачественные опухоли
- **Неправильные позитивные оценки (False Positives Rate):** неправильно классифицированные злокачественные опухоли
- **Правильные негитивные оценки (True Negative Rate):** правильно классифицированные доброкачественные опухоли
- **Неправильные негативные оценки (False Negative Rate):** неправильно классифицированные доброкачественные опухоли
- **Точность (Precision):** Правильные позитивные/(Правильные позитивные + Неправильные позитивные)
- **Полнота (Recall):** Правильные позитивные/(Правильные позитивные + Неправильные негитвные)
- Точность, как следует из названия, говорит о том, насколько точна модель в обнаружении злокачественных опухолей, а полнота - это количество случаев злокачественных опухолей, которые модель способна обнаружить.
- **Компромисс Точность/Полнота:** Чем точнее (избирательнее) наша модель, тем меньше случаев злокачественных опухолей она будет выявлять. Пример: Если модель имеет точность 95%, это значит, злокачественными будут объявлены только те случаи в которых модель имеет точность определения (уверенность) - 95% или более. Допустим, что есть еще 5 случаев, в которых наша модель уверена на 90%, что это злокачественные опухоли. То есть если мы снизим точность, будет больше случаев, которые наша модель сможет обнаружить, но до брокачественных опухолей, которые будут определены как злокачественные станет больше

In [56]:

```
#ROC кривая - по оси Y доля правильно классифицированных положительных ответов (т. явл. мош
#по оси X доля неправильно классифицированных отрицательных ответов (т. не явл. мошенническ
#(вспоминаем ошибки 1-го и 2-го рода)

log_fpr, log_tpr, log_thresold = roc_curve(y_train, log_reg_pred)
knear_fpr, knear_tpr, knear_threshold = roc_curve(y_train, knears_pred)
svc_fpr, svc_tpr, svc_threshold = roc_curve(y_train, svc_pred)
tree_fpr, tree_tpr, tree_threshold = roc_curve(y_train, tree_pred)


def graph_roc_curve_multiple(log_fpr, log_tpr, knear_fpr, knear_tpr, svc_fpr, svc_tpr, tree
    plt.figure(figsize=(12,8))
    plt.title('ROC Кривые \n Лучшие 4 классификатора', fontsize=18)
    plt.plot(log_fpr, log_tpr, label=     'Классификатор - Логистическая регрессия, Оценка:
    plt.plot(knear_fpr, knear_tpr, label= 'Классификатор - К-средних соседей (k-near), Оцен
    plt.plot(svc_fpr, svc_tpr, label=     'Классификатор - Опорные вектора (svc), Оценка: {
    plt.plot(tree_fpr, tree_tpr, label=   'Классификатор - Дерево решений, Оценка: {:.4f}'.
    plt.plot([0, 1], [0, 1], 'k--')
    plt.axis([-0.01, 1, 0, 1])
    plt.ylabel('Правильные позитивные оценки', fontsize=16)
    plt.xlabel('Неправильные позитивные оценки', fontsize=16)
    plt.annotate('Минимальное значение ROC - 50% \n (случайное определение классов)', xy=(0
                 arrowprops=dict(facecolor='#6E726D', shrink=0.05),
                 )
    plt.legend()
```

In [57]:

```
graph_roc_curve_multiple(log_fpr, log_tpr, knear_fpr, knear_tpr, svc_fpr, svc_tpr, tree_fpr
plt.show()
```

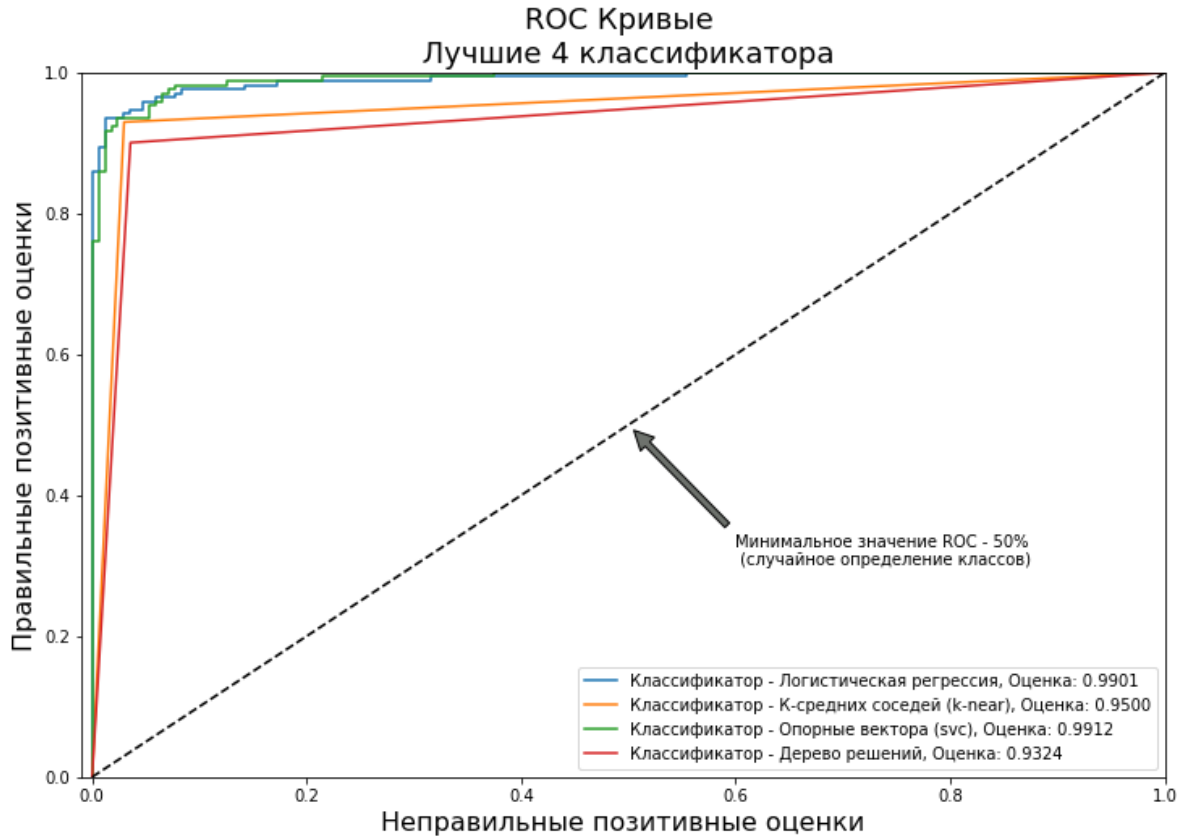

Более подробное рассмотрение логистической регрессии

В этом разделе мы более глубоко рассмотрим **классификатор Логистической регрессии** .

In [58]:

```
def logistic_roc_curve(log_fpr, log_tpr):
    plt.figure(figsize=(12,8))
    plt.title('Логистическая регрессия \n ROC-кривая', fontsize=16)
    plt.plot(log_fpr, log_tpr, 'b-', linewidth=2)
    plt.plot([0, 1], [0, 1], 'r--')
    plt.xlabel('Неправильные позитивные оценки', fontsize=16)
    plt.ylabel('Правильные позитивные оценки', fontsize=16)
    plt.axis([-0.01,1,0,1])


logistic_roc_curve(log_fpr, log_tpr)
plt.show()
```

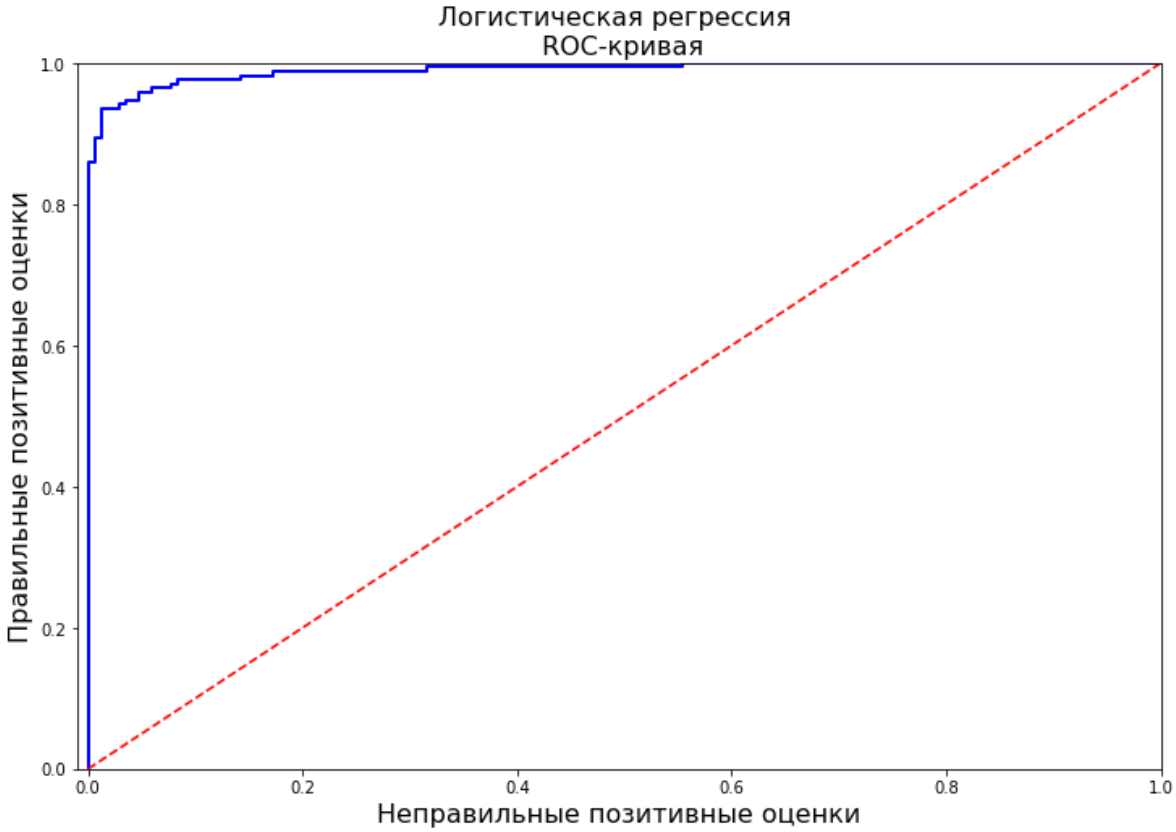

In [59]:

```
from sklearn.metrics import precision_recall_curve

precision, recall, threshold = precision_recall_curve(y_train, log_reg_pred)
```

In [60]:

```
from sklearn.metrics import recall_score, precision_score, f1_score, accuracy_score
y_pred = log_reg.predict(X_train)

# Случай переобучения
print('---' * 40)
print('Переобучение: \n')
print('Точность: {:.2f}'.format(precision_score(y_train, y_pred)))
print('Полнота: {:.2f}'.format(recall_score(y_train, y_pred)))
print('F1-мера: {:.2f}'.format(f1_score(y_train, y_pred)))
print('accuracy: {:.2f}'.format(accuracy_score(y_train, y_pred)))
print('---' * 40)

# Как должно быть
print('Как должно быть: \n')
print("Точность: {:.2f}".format(np.mean(undersample_precision)))
print("Полнота: {:.2f}".format(np.mean(undersample_recall)))
print("F1-мера: {:.2f}".format(np.mean(undersample_f1)))
print("accuracy: {:.2f}".format(np.mean(undersample_accuracy)))
print('---' * 40)
```

```
------------------------------------------------------------------------------------------
------------------------------------------
Переобучение:

Точность: 0.98
Полнота: 0.96
F1-мера: 0.97
accuracy: 0.97
------------------------------------------------------------------------------------------
------------------------------------------
Как должно быть:

Точность: 0.34
Полнота: 0.29
F1-мера: 0.31
accuracy: 0.97
------------------------------------------------------------------------------------------
------------------------------------------
```

In [61]:

```
undersample_y_score = log_reg.decision_function(original_Xtest)
```

In [62]:

```
from sklearn.metrics import average_precision_score

undersample_average_precision = average_precision_score(original_ytest, undersample_y_score

print('Среднее значение точность/полнота: {0:0.2f}'.format(
      undersample_average_precision))
```

```
Среднее значение точность/полнота: 0.99
```

In [63]:

```
from sklearn.metrics import precision_recall_curve
import matplotlib.pyplot as plt

fig = plt.figure(figsize=(12,6))

precision, recall, _ = precision_recall_curve(original_ytest, undersample_y_score)

plt.step(recall, precision, color='#004a93', alpha=0.2,
         where='post')
plt.fill_between(recall, precision, step='post', alpha=0.2,
                 color='#48a6ff')

plt.xlabel('Полнота')
plt.ylabel('Точность')
plt.ylim([0.0, 1.05])
plt.xlim([0.0, 1.0])
plt.title('Кривая точность/полнота (для набора UnderSampling) \n Средняя оценка значения то
          undersample_average_precision), fontsize=16)
plt.show()
```

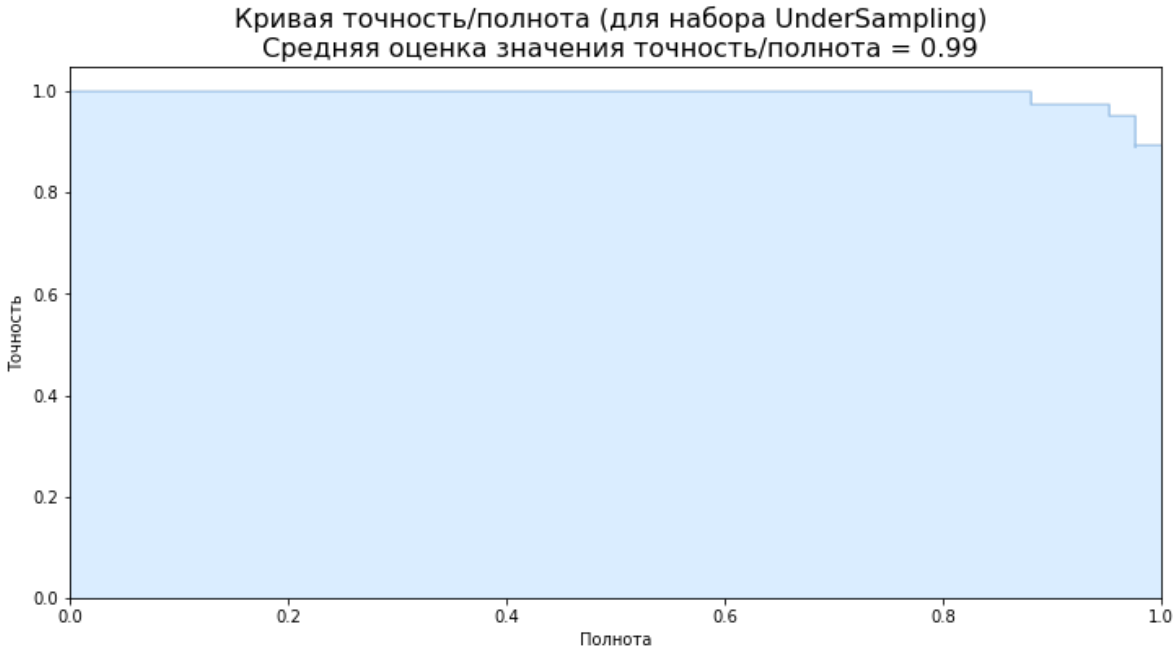

SMOTE техника (Over-Sampling):

Понимание SMOTE:

- **Устранение дисбаланса классов:** SMOTE создает искусственные точки из класса меньшинства, для того, чтобы достигнуть баланса между классами меньшинства и большинства.
- **Расположение искусственных точек:** SMOTE расчитывает прямые между соседними точками класса меньшинства, и создает на них искусственные точки.
- **Конечный эффект:** Сохраняется больше информации, поскольку не надо удалять строки, как это делается при создании случайной недостаточной выборки (Random Under-Sampling).

- **Компромисс точности и времени обучения:** возможно, что SMOTE позволит достичь большей точности, чем при Random Under-Sampling, но обучение займет больше времени, так как данных становится больше (в нашем случае не на много).

Переобучение в течение кросс-валидации:

В анализе подвыбоке полученной методом Random Under-Sampling рассмотрим часто совершаемую ошибку. Если нужно уменьшить или увеличить выборку данных, не следует это делать перед кросс-валидацией. Почему? Потому, что это будет непосредственно влиять на проверочный набор данных, который используется при кросс-валидации, вызывая проблему «утечки данных». **В следующем разделе вы увидите удивительные оценки точности и полноты, но на самом деле получаемые значения являются следствие переобучения!**

Неправильный путь:

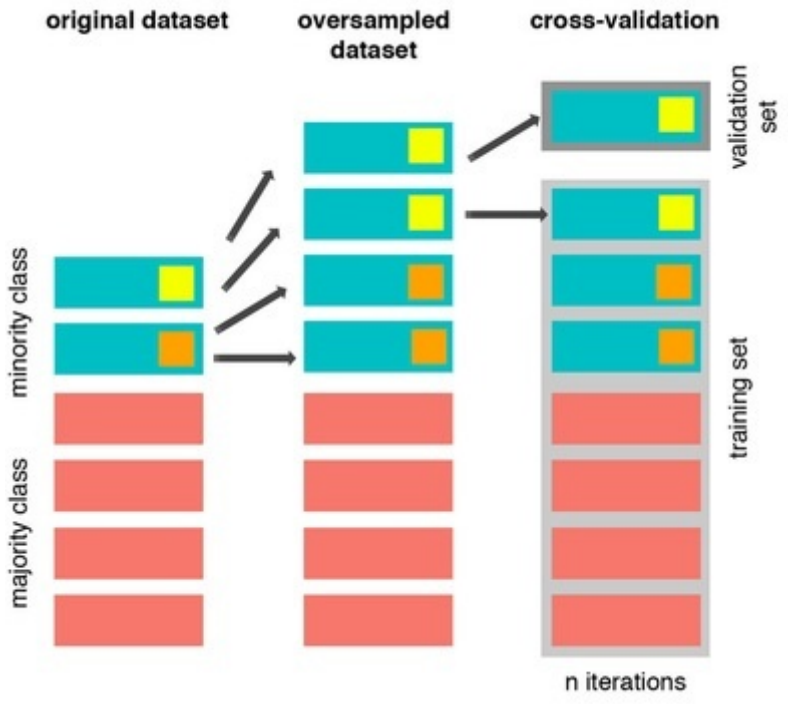

Как упоминалось ранее, если взять класс меньшинства и создать искусственные точки перед кросс-валидацией, будет оказано определенное влияние на проверочный набор данных, используемый для кросс-валидации. Вспомним, как работает кросс-валидация, давайте предположим, что мы разбиваем данные на 5 пакетов, 4/5 набора данных будет обучающим набором, а 1/5 будет проверочным набором. Проверочный набор не должен быть тронут! По этой причине мы должны создать искусственные точки данных «во время» кросс-валидации, а не до этого:

Правильный путь:

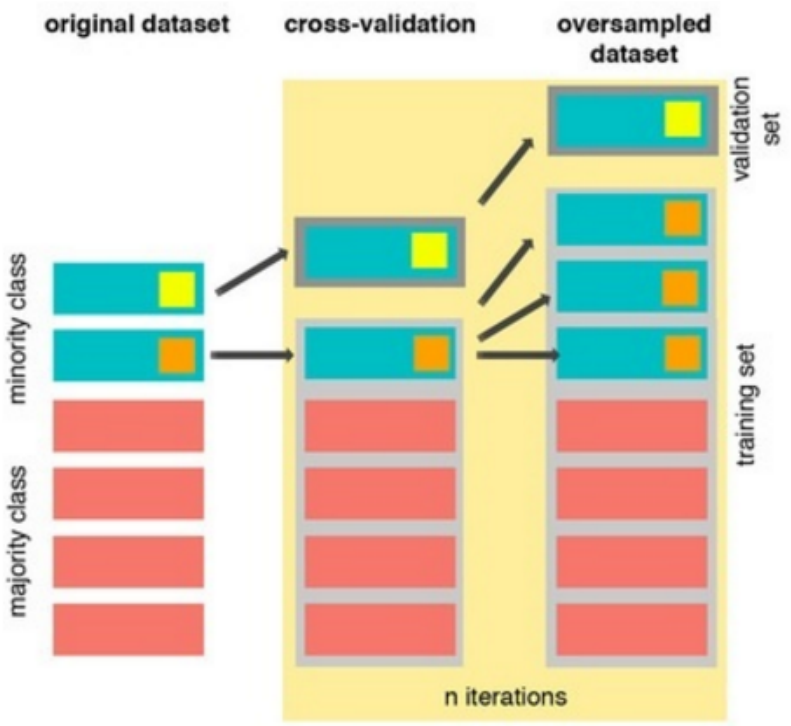

Как было сказанно выше, алгоритм SMOTE выполняется «во время» кросс-валидации, а не «до». Искусственные данные создаются только для обучающего набора, не оказывая влияния на проверочный набор.

In [64]:

```
from imblearn.over_sampling import SMOTE
from sklearn.model_selection import train_test_split, RandomizedSearchCV


print('Размер выборки X (train): {} | Размер выборки y (train): {}'.format(len(original_Xtr
print('Размер выборки X (test): {} | Размер выборки y (test): {}'.format(len(original_Xtest

# Список для добавленя значений, и дальнейшего нахождения среднего
accuracy_lst = []
precision_lst = []
recall_lst = []
f1_lst = []
auc_lst = []

# Классификатор с оптимальными параметрами
# log_reg_sm = grid_log_reg.best_estimator_
log_reg_sm = LogisticRegression()

rand_log_reg = RandomizedSearchCV(LogisticRegression(), log_reg_params, n_iter=4)


# Применение метода SMOTE
# Правильный путь использования кросс-валидации
# Параметры
log_reg_params = {"penalty": ['l1', 'l2'], 'C': [0.001, 0.01, 0.1, 1, 10, 100, 1000]}
for train, test in sss.split(original_Xtrain, original_ytrain):
    pipeline = imbalanced_make_pipeline(SMOTE(sampling_strategy='minority'), rand_log_reg)
    # SMOTE происходит во время кросс-валидации, а не раньше...
    model = pipeline.fit(original_Xtrain[train], original_ytrain[train])
    best_est = rand_log_reg.best_estimator_
    prediction = best_est.predict(original_Xtrain[test])

    accuracy_lst.append(pipeline.score(original_Xtrain[test], original_ytrain[test]))
    precision_lst.append(precision_score(original_ytrain[test], prediction))
    recall_lst.append(recall_score(original_ytrain[test], prediction))
    f1_lst.append(f1_score(original_ytrain[test], prediction))
    auc_lst.append(roc_auc_score(original_ytrain[test], prediction))

print('---' * 40)
print('')
print("accuracy: {}".format(np.mean(accuracy_lst)))
print("Точность: {}".format(np.mean(precision_lst)))
print("Полнота: {}".format(np.mean(recall_lst)))
print("F1-мера: {}".format(np.mean(f1_lst)))
print('---' * 40)
```

```
Размер выборки X (train): 456 | Размер выборки y (train): 456
Размер выборки X (test): 113 | Размер выборки y (test): 113
--------------------------------------------------------------------------------
------------------------------------------

accuracy: 0.9626851409460105
Точность: 0.9596154825566592
Полнота: 0.9411764705882353
F1-мера: 0.9489921358982703
--------------------------------------------------------------------------------
------------------------------------------
```

In [65]:

```
labels = ['Доброкачественные', 'Злокачественные']
smote_prediction = best_est.predict(original_Xtest)
print(classification_report(original_ytest, smote_prediction, target_names=labels))
```

```
                   precision    recall  f1-score   support

Доброкачественные       0.99      0.97      0.98        71
  Злокачественные       0.95      0.98      0.96        42

         accuracy                           0.97       113
        macro avg       0.97      0.97      0.97       113
     weighted avg       0.97      0.97      0.97       113
```

In [66]:

```
y_score = best_est.decision_function(original_Xtest)
```

In [67]:

```
average_precision = average_precision_score(original_ytest, y_score)

print('Среднее значение точность/полнота: {0:0.2f}'.format(
      average_precision))
```

```
Среднее значение точность/полнота: 1.00
```

In [68]:

```
fig = plt.figure(figsize=(12,6))

precision, recall, _ = precision_recall_curve(original_ytest, y_score)

plt.step(recall, precision, color='r', alpha=0.2,
         where='post')
plt.fill_between(recall, precision, step='post', alpha=0.2,
                 color='#F59B00')

plt.xlabel('Полнота')
plt.ylabel('Точность')
plt.ylim([0.0, 1.05])
plt.xlim([0.0, 1.0])
plt.title('Значение точность/полнота (для набора OverSampling): \n Среднее значение точност
          average_precision), fontsize=16)
plt.show()
```

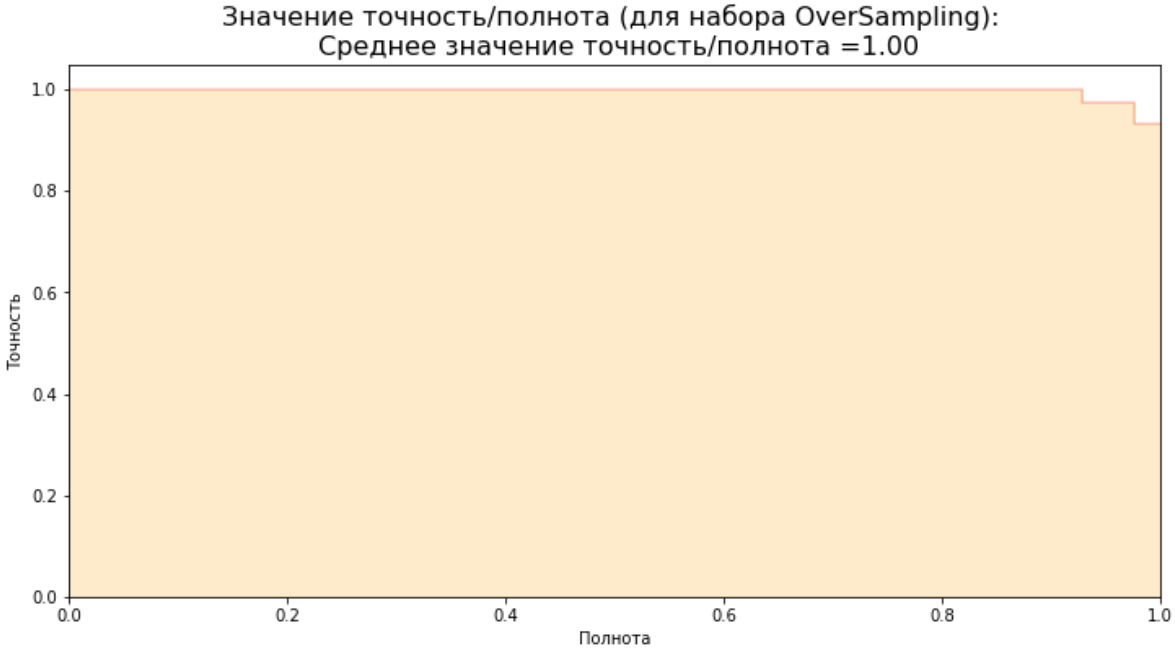

In [69]:

```
# Алгоритм SMOTE (OverSampling) после разделения и кросс-валидации
sm = SMOTE(ratio='minority', random_state=42)
# Xsm_train, ysm_train = sm.fit_sample(X_train, y_train)


# This will be the data were we are going to
Xsm_train, ysm_train = sm.fit_sample(original_Xtrain, original_ytrain)
```

In [70]:

```
#  Мы улучшаем значение примерно на 2% We Improve the score by 2% points approximately
# Использование GridSearchCV и других моделей.

# Logistic Regression
t0 = time.time()
log_reg_sm = grid_log_reg.best_estimator_
log_reg_sm.fit(Xsm_train, ysm_train)
t1 = time.time()
print("Обучение на наборе данных OverSampleing заняла: {} sec".format(t1 - t0))
```

```
Обучение на наборе данных OverSampleing заняла: 0.0029909610748291016 sec
```

Тестирование классификаторов

- **Random UnderSampling:** Оценим окончательную производительность классификационных моделей на подмножестве данных UnderSampling. **(Не на данных исходного набора)**
- **Классификационные модели:** Лучшими моделями были **Логистическая регрессия** и **классификатор метода опорных векторов (SVC).**

Матрица ошибок:

Что показывает матрица ошибок:

- **Верхний левый квадрат:** Количество **правильно** классифицированных **доброкачественных** опухолей.
- **Верхний правый квадрат:** Количество **не правильно** классифицированных доброкачественных опухолей, т.е. количество опухолей классифицированных злокачественными, но на самом деле **не являющиеся злокачественными**.
- **Нижний левый квадрат:** Количество **не правильно** классифицированных злокачественных опухолей, т.е. количество опухолей классифицированных доброкачественными, но на самом деле **являющиеся злокачественными** .
- **Нижний правый квадрат:** Количество **правильно** классифицированных **злокачественных** опухолей.

In [71]:

```
from sklearn.metrics import confusion_matrix

# Логистическая регрессия на наборе данных, полученным с использованием метода SMOTE
y_pred_log_reg = log_reg_sm.predict(X_test)

# Другие модели на наборе данных, полученным с использованием метода UnderSampling
y_pred_knear = knears_neighbors.predict(X_test)
y_pred_svc = svc.predict(X_test)
y_pred_tree = tree_clf.predict(X_test)


log_reg_cf = confusion_matrix(y_test, y_pred_log_reg)
kneighbors_cf = confusion_matrix(y_test, y_pred_knear)
svc_cf = confusion_matrix(y_test, y_pred_svc)
tree_cf = confusion_matrix(y_test, y_pred_tree)

fig, ax = plt.subplots(2, 2,figsize=(18,12))

print("Матрацы ошибок для различных классификаторов:")
sns.heatmap(log_reg_cf, ax=ax[0][0], annot=True, cmap=plt.cm.copper)
ax[0, 0].set_title("Логистическая регрессия", fontsize=16)
ax[0, 0].set_xticklabels(['', ''], fontsize=14, rotation=90)
ax[0, 0].set_yticklabels(['', ''], fontsize=14, rotation=360)

sns.heatmap(kneighbors_cf, ax=ax[0][1], annot=True, cmap=plt.cm.copper)
ax[0][1].set_title("К-средних соседей", fontsize=16)
ax[0][1].set_xticklabels(['', ''], fontsize=14, rotation=90)
ax[0][1].set_yticklabels(['', ''], fontsize=14, rotation=360)

sns.heatmap(svc_cf, ax=ax[1][0], annot=True, cmap=plt.cm.copper)
ax[1][0].set_title("Опорные вектора", fontsize=16)
ax[1][0].set_xticklabels(['', ''], fontsize=14, rotation=90)
ax[1][0].set_yticklabels(['', ''], fontsize=14, rotation=360)

sns.heatmap(tree_cf, ax=ax[1][1], annot=True, cmap=plt.cm.copper)
ax[1][1].set_title("Дерево решений", fontsize=16)
ax[1][1].set_xticklabels(['', ''], fontsize=14, rotation=90)
ax[1][1].set_yticklabels(['', ''], fontsize=14, rotation=360)


plt.show()
```

```
Матрацы ошибок для различных классификаторов:
```

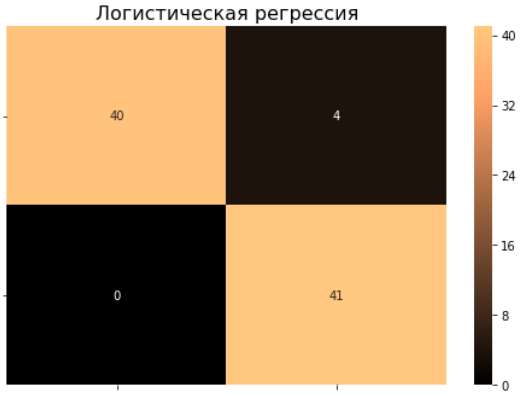
Логистическая регрессия
40
4
0
41
40
32
24
16
8
0


К-средних соседей
40
4
5
36
36
30
24
18
12
6

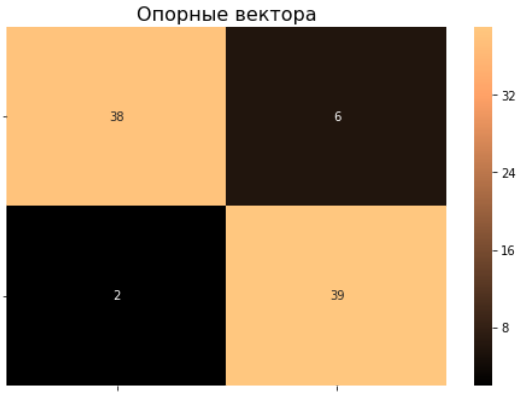
Опорные вектора
38
6
2
39
32
24
16
8

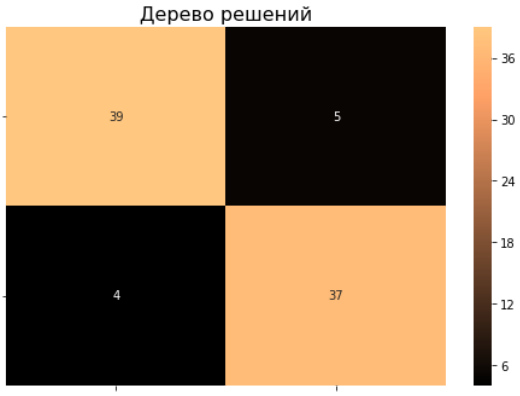
Дерево решений
39
5
4
37
36
30
24
18
12
6

In [72]:

```
from sklearn.metrics import classification_report

print('Логистическая регрессия:')
print(classification_report(y_test, y_pred_log_reg))

print('K-средних соседей:')
print(classification_report(y_test, y_pred_knear))

print('Опорные вектора:')
print(classification_report(y_test, y_pred_svc))

print('Дерево решений:')
print(classification_report(y_test, y_pred_tree))
```

```
Логистическая регрессия:
              precision    recall  f1-score   support

           0       1.00      0.91      0.95        44
           1       0.91      1.00      0.95        41

    accuracy                           0.95        85
   macro avg       0.96      0.95      0.95        85
weighted avg       0.96      0.95      0.95        85

K-средних соседей:
              precision    recall  f1-score   support

           0       0.89      0.91      0.90        44
           1       0.90      0.88      0.89        41

    accuracy                           0.89        85
   macro avg       0.89      0.89      0.89        85
weighted avg       0.89      0.89      0.89        85

Опорные вектора:
              precision    recall  f1-score   support

           0       0.95      0.86      0.90        44
           1       0.87      0.95      0.91        41

    accuracy                           0.91        85
   macro avg       0.91      0.91      0.91        85
weighted avg       0.91      0.91      0.91        85

Дерево решений:
              precision    recall  f1-score   support

           0       0.91      0.89      0.90        44
           1       0.88      0.90      0.89        41

    accuracy                           0.89        85
   macro avg       0.89      0.89      0.89        85
weighted avg       0.89      0.89      0.89        85
```

In [73]:

```
# Окончательные значения на тестовом наборе для классификатора логистической регрессии
from sklearn.metrics import accuracy_score

# Логистическая регрессия с набором данных Under-Sampling
y_pred = log_reg.predict(X_test)
undersample_score = accuracy_score(y_test, y_pred)


# Логистическая регрессия с использованием метода SMOTE (Лучшее значение accuracy с SMOTE)
y_pred_sm = best_est.predict(original_Xtest)
oversample_score = accuracy_score(original_ytest, y_pred_sm)


d = {'Technique': ['Random UnderSampling', 'Oversampling (SMOTE)'], 'Score': [undersample_s
final_df = pd.DataFrame(data=d)

# Move column
score = final_df['Score']
final_df.drop('Score', axis=1, inplace=True)
final_df.insert(1, 'Score', score)

print("Значение accuracy для классификатора Логистической регрессии \n на наборах данных, п

final_df
```

```
Значение accuracy для классификатора Логистической регрессии
 на наборах данных, полученных разными техниками:
```

Out[73]:

	Technique	Score
0	Random UnderSampling	0.952941
1	Oversampling (SMOTE)	0.973451

Нейронные сети, обучаемые на разных наборах данных Under-Sample и Over-Sample (SMOTE)

Будет реализована простая нейронная сеть (с одним скрытым слоем), чтобы увидеть, на каком наборе данных (under-sample и over-sample), реализована лучшая модель.

- **Набор данных:** В финальной фазе тестирования модель будет обучена на обоих наборах данных: **Random Under-Sample** и **Over-Sample**. Для получения оценки предсказательной способности будет использоваться **исходный набор тестовых данных.**
- **Структура нейронной сети:** Это будет простая модель, состоящая из одного входного слоя (где количество узлов равно количеству признаков объектов), один скрытый слой с 18 узлами и один выходной слой, состоящий из двух возможных результатов 0 или 1.

Keras || UnderSampling

In [74]:

```
import tensorflow.keras
from tensorflow.keras import backend as K
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Activation
from tensorflow.keras.layers import Dense
from tensorflow.keras.optimizers import Adam
from tensorflow.keras.metrics import categorical_crossentropy

n_inputs = X_train.shape[1]

undersample_model = Sequential([
    Dense(n_inputs, input_shape=(n_inputs, ), activation='relu'),
    Dense(18, activation='relu'),
    Dense(2, activation='softmax')
])
```

In [75]:

```
undersample_model.summary()
```

```
Model: "sequential"
_________________________________________________________________
Layer (type)                 Output Shape              Param #
=================================================================
dense (Dense)                (None, 18)                342
_________________________________________________________________
dense_1 (Dense)              (None, 18)                342
_________________________________________________________________
dense_2 (Dense)              (None, 2)                 38
=================================================================
Total params: 722
Trainable params: 722
Non-trainable params: 0
_________________________________________________________________
```

In [76]:

```
undersample_model.compile(Adam(lr=0.001), loss='sparse_categorical_crossentropy', metrics=[
```

In [77]:

```
undersample_model.fit(X_train, y_train, validation_split=0.2, batch_size=25, epochs=50, shu
```

```
Train on 271 samples, validate on 68 samples
Epoch 1/50
271/271 - 1s - loss: 0.6852 - accuracy: 0.5867 - val_loss: 0.6029 - val_accu
racy: 0.7206
Epoch 2/50
271/271 - 0s - loss: 0.6221 - accuracy: 0.7454 - val_loss: 0.5651 - val_accu
racy: 0.8088
Epoch 3/50
271/271 - 0s - loss: 0.5623 - accuracy: 0.8044 - val_loss: 0.5227 - val_accu
racy: 0.8235
Epoch 4/50
271/271 - 0s - loss: 0.5020 - accuracy: 0.8339 - val_loss: 0.4803 - val_accu
racy: 0.8824
Epoch 5/50
271/271 - 0s - loss: 0.4438 - accuracy: 0.8782 - val_loss: 0.4383 - val_accu
racy: 0.8824
Epoch 6/50
271/271 - 0s - loss: 0.3870 - accuracy: 0.9077 - val_loss: 0.3957 - val_accu
racy: 0.8824
Epoch 7/50
271/271 - 0s - loss: 0.3358 - accuracy: 0.9262 - val_loss: 0.3553 - val_accu
racy: 0.8676
Epoch 8/50
271/271 - 0s - loss: 0.2922 - accuracy: 0.9262 - val_loss: 0.3159 - val_accu
racy: 0.8971
Epoch 9/50
271/271 - 0s - loss: 0.2565 - accuracy: 0.9336 - val_loss: 0.2829 - val_accu
racy: 0.8971
Epoch 10/50
271/271 - 0s - loss: 0.2278 - accuracy: 0.9299 - val_loss: 0.2541 - val_accu
racy: 0.9118
Epoch 11/50
271/271 - 0s - loss: 0.2051 - accuracy: 0.9446 - val_loss: 0.2307 - val_accu
racy: 0.9118
Epoch 12/50
271/271 - 0s - loss: 0.1883 - accuracy: 0.9483 - val_loss: 0.2106 - val_accu
racy: 0.9118
Epoch 13/50
271/271 - 0s - loss: 0.1730 - accuracy: 0.9483 - val_loss: 0.1929 - val_accu
racy: 0.9412
Epoch 14/50
271/271 - 0s - loss: 0.1613 - accuracy: 0.9557 - val_loss: 0.1767 - val_accu
racy: 0.9559
Epoch 15/50
271/271 - 0s - loss: 0.1505 - accuracy: 0.9594 - val_loss: 0.1626 - val_accu
racy: 0.9559
Epoch 16/50
271/271 - 0s - loss: 0.1420 - accuracy: 0.9594 - val_loss: 0.1498 - val_accu
racy: 0.9559
Epoch 17/50
271/271 - 0s - loss: 0.1343 - accuracy: 0.9594 - val_loss: 0.1389 - val_accu
racy: 0.9706
Epoch 18/50
271/271 - 0s - loss: 0.1279 - accuracy: 0.9594 - val_loss: 0.1289 - val_accu
racy: 0.9706
Epoch 19/50
271/271 - 0s - loss: 0.1216 - accuracy: 0.9631 - val_loss: 0.1203 - val_accu
```

```
racy: 0.9706
Epoch 20/50
271/271 - 0s - loss: 0.1162 - accuracy: 0.9631 - val_loss: 0.1122 - val_accu
racy: 0.9706
Epoch 21/50
271/271 - 0s - loss: 0.1114 - accuracy: 0.9631 - val_loss: 0.1057 - val_accu
racy: 0.9706
Epoch 22/50
271/271 - 0s - loss: 0.1067 - accuracy: 0.9631 - val_loss: 0.0997 - val_accu
racy: 0.9706
Epoch 23/50
271/271 - 0s - loss: 0.1031 - accuracy: 0.9631 - val_loss: 0.0945 - val_accu
racy: 0.9706
Epoch 24/50
271/271 - 0s - loss: 0.0988 - accuracy: 0.9631 - val_loss: 0.0899 - val_accu
racy: 0.9706
Epoch 25/50
271/271 - 0s - loss: 0.0952 - accuracy: 0.9668 - val_loss: 0.0865 - val_accu
racy: 0.9706
Epoch 26/50
271/271 - 0s - loss: 0.0918 - accuracy: 0.9705 - val_loss: 0.0817 - val_accu
racy: 0.9706
Epoch 27/50
271/271 - 0s - loss: 0.0886 - accuracy: 0.9705 - val_loss: 0.0784 - val_accu
racy: 0.9706
Epoch 28/50
271/271 - 0s - loss: 0.0856 - accuracy: 0.9705 - val_loss: 0.0751 - val_accu
racy: 0.9706
Epoch 29/50
271/271 - 0s - loss: 0.0833 - accuracy: 0.9705 - val_loss: 0.0720 - val_accu
racy: 0.9853
Epoch 30/50
271/271 - 0s - loss: 0.0804 - accuracy: 0.9705 - val_loss: 0.0712 - val_accu
racy: 0.9853
Epoch 31/50
271/271 - 0s - loss: 0.0783 - accuracy: 0.9705 - val_loss: 0.0688 - val_accu
racy: 0.9853
Epoch 32/50
271/271 - 0s - loss: 0.0760 - accuracy: 0.9742 - val_loss: 0.0680 - val_accu
racy: 0.9853
Epoch 33/50
271/271 - 0s - loss: 0.0737 - accuracy: 0.9742 - val_loss: 0.0668 - val_accu
racy: 0.9853
Epoch 34/50
271/271 - 0s - loss: 0.0720 - accuracy: 0.9742 - val_loss: 0.0640 - val_accu
racy: 0.9706
Epoch 35/50
271/271 - 0s - loss: 0.0698 - accuracy: 0.9742 - val_loss: 0.0637 - val_accu
racy: 0.9853
Epoch 36/50
271/271 - 0s - loss: 0.0679 - accuracy: 0.9742 - val_loss: 0.0635 - val_accu
racy: 0.9853
Epoch 37/50
271/271 - 0s - loss: 0.0662 - accuracy: 0.9742 - val_loss: 0.0620 - val_accu
racy: 0.9853
Epoch 38/50
271/271 - 0s - loss: 0.0646 - accuracy: 0.9742 - val_loss: 0.0604 - val_accu
racy: 0.9706
Epoch 39/50
271/271 - 0s - loss: 0.0624 - accuracy: 0.9779 - val_loss: 0.0600 - val_accu
racy: 0.9706
```

```
Epoch 40/50
271/271 - 0s - loss: 0.0611 - accuracy: 0.9779 - val_loss: 0.0593 - val_accu
racy: 0.9853
Epoch 41/50
271/271 - 0s - loss: 0.0600 - accuracy: 0.9779 - val_loss: 0.0570 - val_accu
racy: 0.9706
Epoch 42/50
271/271 - 0s - loss: 0.0579 - accuracy: 0.9779 - val_loss: 0.0579 - val_accu
racy: 0.9706
Epoch 43/50
271/271 - 0s - loss: 0.0564 - accuracy: 0.9779 - val_loss: 0.0572 - val_accu
racy: 0.9853
Epoch 44/50
271/271 - 0s - loss: 0.0549 - accuracy: 0.9779 - val_loss: 0.0576 - val_accu
racy: 0.9853
Epoch 45/50
271/271 - 0s - loss: 0.0535 - accuracy: 0.9779 - val_loss: 0.0552 - val_accu
racy: 0.9706
Epoch 46/50
271/271 - 0s - loss: 0.0527 - accuracy: 0.9779 - val_loss: 0.0522 - val_accu
racy: 0.9706
Epoch 47/50
271/271 - 0s - loss: 0.0507 - accuracy: 0.9852 - val_loss: 0.0547 - val_accu
racy: 0.9706
Epoch 48/50
271/271 - 0s - loss: 0.0494 - accuracy: 0.9852 - val_loss: 0.0553 - val_accu
racy: 0.9706
Epoch 49/50
271/271 - 0s - loss: 0.0483 - accuracy: 0.9852 - val_loss: 0.0538 - val_accu
racy: 0.9706
Epoch 50/50
271/271 - 0s - loss: 0.0469 - accuracy: 0.9852 - val_loss: 0.0529 - val_accu
racy: 0.9706
```

Out[77]:

```
<tensorflow.python.keras.callbacks.History at 0x1f8151332e8>
```

In [78]:

```
undersample_predictions = undersample_model.predict(original_Xtest, batch_size=200, verbose
```

In [79]:

```
undersample_fraud_predictions = undersample_model.predict_classes(original_Xtest, batch_siz
```

In [80]:

```
import itertools

# Создание матрицы ошибок
def plot_confusion_matrix(cm, classes,
                          normalize=False,
                          title='Матрица ошибок',
                          cmap=plt.cm.Blues):
    """
    Эта функция делает график матрицы ошибок.
    Нормализация может быть применена установкой `normalize=True`.
    """
    if normalize:
        cm = cm.astype('float') / cm.sum(axis=1)[:, np.newaxis]
        print("Нормализованная матрица ошибок")
    else:
        print('Матрица ошибок без нормализации')

    print(cm)

    plt.imshow(cm, interpolation='nearest', cmap=cmap)
    plt.title(title, fontsize=14)
    plt.colorbar()
    tick_marks = np.arange(len(classes))
    plt.xticks(tick_marks, classes, rotation=45)
    plt.yticks(tick_marks, classes)

    fmt = '.2f' if normalize else 'd'
    thresh = cm.max() / 2.
    for i, j in itertools.product(range(cm.shape[0]), range(cm.shape[1])):
        plt.text(j, i, format(cm[i, j], fmt),
                 horizontalalignment="center",
                 color="white" if cm[i, j] > thresh else "black")

    plt.tight_layout()
#     plt.ylabel('Позитивные ответы')
#     plt.xlabel('Негативные ответы')
```

In [81]:

```
undersample_cm = confusion_matrix(original_ytest, undersample_fraud_predictions)
actual_cm = confusion_matrix(original_ytest, original_ytest)
labels = ['Д-кач.', 'З-кач.']

fig = plt.figure(figsize=(16,8))

fig.add_subplot(221)
plot_confusion_matrix(undersample_cm, labels, title="Random UnderSample \n Матрица Ошибок",

fig.add_subplot(222)
plot_confusion_matrix(actual_cm, labels, title="100% accuracy \n Матрица ошибок", cmap=plt.
```

```
Матрица ошибок без нормализации
[[68  3]
 [ 0 42]]
Матрица ошибок без нормализации
[[71  0]
 [ 0 42]]
```

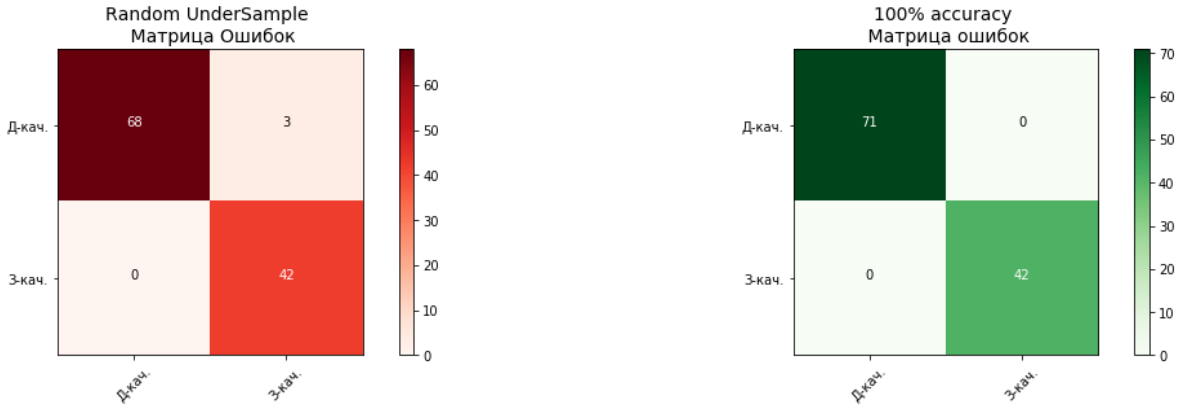

Keras || OverSampling (SMOTE):

In [82]:

```
n_inputs = Xsm_train.shape[1]

oversample_model = Sequential([
    Dense(n_inputs, input_shape=(n_inputs, ), activation='relu'),
    Dense(18, activation='relu'),
    Dense(2, activation='softmax')
])
```

In [83]:

```
oversample_model.compile(Adam(lr=0.001), loss='sparse_categorical_crossentropy', metrics=['
```

In [84]:

```
oversample_model.fit(Xsm_train, ysm_train, validation_split=0.2, batch_size=300, epochs=50,
```

```
Train on 457 samples, validate on 115 samples
Epoch 1/50
457/457 - 0s - loss: 0.7728 - accuracy: 0.4508 - val_loss: 0.9864 - val_accu
racy: 0.0609
Epoch 2/50
457/457 - 0s - loss: 0.7471 - accuracy: 0.4705 - val_loss: 0.9647 - val_accu
racy: 0.0696
Epoch 3/50
457/457 - 0s - loss: 0.7238 - accuracy: 0.4923 - val_loss: 0.9446 - val_accu
racy: 0.0783
Epoch 4/50
457/457 - 0s - loss: 0.7001 - accuracy: 0.5230 - val_loss: 0.9255 - val_accu
racy: 0.0870
Epoch 5/50
457/457 - 0s - loss: 0.6788 - accuracy: 0.5492 - val_loss: 0.9078 - val_accu
racy: 0.0870
Epoch 6/50
457/457 - 0s - loss: 0.6585 - accuracy: 0.5711 - val_loss: 0.8915 - val_accu
racy: 0.0870
Epoch 7/50
457/457 - 0s - loss: 0.6389 - accuracy: 0.5842 - val_loss: 0.8755 - val_accu
racy: 0.1043
Epoch 8/50
457/457 - 0s - loss: 0.6203 - accuracy: 0.5996 - val_loss: 0.8605 - val_accu
racy: 0.1217
Epoch 9/50
457/457 - 0s - loss: 0.6030 - accuracy: 0.6149 - val_loss: 0.8474 - val_accu
racy: 0.1217
Epoch 10/50
457/457 - 0s - loss: 0.5864 - accuracy: 0.6368 - val_loss: 0.8340 - val_accu
racy: 0.1391
Epoch 11/50
457/457 - 0s - loss: 0.5707 - accuracy: 0.6565 - val_loss: 0.8206 - val_accu
racy: 0.1739
Epoch 12/50
457/457 - 0s - loss: 0.5555 - accuracy: 0.6718 - val_loss: 0.8074 - val_accu
racy: 0.2348
Epoch 13/50
457/457 - 0s - loss: 0.5410 - accuracy: 0.6915 - val_loss: 0.7938 - val_accu
racy: 0.2870
Epoch 14/50
457/457 - 0s - loss: 0.5270 - accuracy: 0.7177 - val_loss: 0.7795 - val_accu
racy: 0.3304
Epoch 15/50
457/457 - 0s - loss: 0.5137 - accuracy: 0.7462 - val_loss: 0.7646 - val_accu
racy: 0.3826
Epoch 16/50
457/457 - 0s - loss: 0.5006 - accuracy: 0.7724 - val_loss: 0.7495 - val_accu
racy: 0.4435
Epoch 17/50
457/457 - 0s - loss: 0.4880 - accuracy: 0.7834 - val_loss: 0.7343 - val_accu
racy: 0.5217
Epoch 18/50
457/457 - 0s - loss: 0.4757 - accuracy: 0.8053 - val_loss: 0.7192 - val_accu
racy: 0.6174
Epoch 19/50
457/457 - 0s - loss: 0.4638 - accuracy: 0.8184 - val_loss: 0.7037 - val_accu
```

```
racy: 0.6522
Epoch 20/50
457/457 - 0s - loss: 0.4518 - accuracy: 0.8403 - val_loss: 0.6881 - val_accu
racy: 0.7130
Epoch 21/50
457/457 - 0s - loss: 0.4406 - accuracy: 0.8665 - val_loss: 0.6720 - val_accu
racy: 0.7391
Epoch 22/50
457/457 - 0s - loss: 0.4295 - accuracy: 0.8818 - val_loss: 0.6558 - val_accu
racy: 0.7652
Epoch 23/50
457/457 - 0s - loss: 0.4185 - accuracy: 0.8972 - val_loss: 0.6393 - val_accu
racy: 0.8000
Epoch 24/50
457/457 - 0s - loss: 0.4076 - accuracy: 0.9037 - val_loss: 0.6225 - val_accu
racy: 0.8174
Epoch 25/50
457/457 - 0s - loss: 0.3971 - accuracy: 0.9015 - val_loss: 0.6056 - val_accu
racy: 0.8174
Epoch 26/50
457/457 - 0s - loss: 0.3866 - accuracy: 0.9081 - val_loss: 0.5889 - val_accu
racy: 0.8261
Epoch 27/50
457/457 - 0s - loss: 0.3766 - accuracy: 0.9103 - val_loss: 0.5723 - val_accu
racy: 0.8348
Epoch 28/50
457/457 - 0s - loss: 0.3665 - accuracy: 0.9190 - val_loss: 0.5557 - val_accu
racy: 0.8348
Epoch 29/50
457/457 - 0s - loss: 0.3568 - accuracy: 0.9212 - val_loss: 0.5390 - val_accu
racy: 0.8435
Epoch 30/50
457/457 - 0s - loss: 0.3473 - accuracy: 0.9168 - val_loss: 0.5223 - val_accu
racy: 0.8435
Epoch 31/50
457/457 - 0s - loss: 0.3379 - accuracy: 0.9168 - val_loss: 0.5060 - val_accu
racy: 0.8696
Epoch 32/50
457/457 - 0s - loss: 0.3286 - accuracy: 0.9190 - val_loss: 0.4900 - val_accu
racy: 0.8783
Epoch 33/50
457/457 - 0s - loss: 0.3196 - accuracy: 0.9256 - val_loss: 0.4744 - val_accu
racy: 0.8870
Epoch 34/50
457/457 - 0s - loss: 0.3107 - accuracy: 0.9256 - val_loss: 0.4590 - val_accu
racy: 0.8957
Epoch 35/50
457/457 - 0s - loss: 0.3020 - accuracy: 0.9278 - val_loss: 0.4439 - val_accu
racy: 0.9130
Epoch 36/50
457/457 - 0s - loss: 0.2937 - accuracy: 0.9278 - val_loss: 0.4293 - val_accu
racy: 0.9130
Epoch 37/50
457/457 - 0s - loss: 0.2854 - accuracy: 0.9300 - val_loss: 0.4154 - val_accu
racy: 0.9217
Epoch 38/50
457/457 - 0s - loss: 0.2772 - accuracy: 0.9300 - val_loss: 0.4017 - val_accu
racy: 0.9217
Epoch 39/50
457/457 - 0s - loss: 0.2695 - accuracy: 0.9300 - val_loss: 0.3882 - val_accu
racy: 0.9217
```

```
Epoch 40/50
457/457 - 0s - loss: 0.2620 - accuracy: 0.9365 - val_loss: 0.3750 - val_accu
racy: 0.9304
Epoch 41/50
457/457 - 0s - loss: 0.2547 - accuracy: 0.9365 - val_loss: 0.3619 - val_accu
racy: 0.9391
Epoch 42/50
457/457 - 0s - loss: 0.2476 - accuracy: 0.9409 - val_loss: 0.3495 - val_accu
racy: 0.9391
Epoch 43/50
457/457 - 0s - loss: 0.2407 - accuracy: 0.9409 - val_loss: 0.3375 - val_accu
racy: 0.9478
Epoch 44/50
457/457 - 0s - loss: 0.2341 - accuracy: 0.9453 - val_loss: 0.3260 - val_accu
racy: 0.9478
Epoch 45/50
457/457 - 0s - loss: 0.2275 - accuracy: 0.9475 - val_loss: 0.3150 - val_accu
racy: 0.9478
Epoch 46/50
457/457 - 0s - loss: 0.2215 - accuracy: 0.9519 - val_loss: 0.3042 - val_accu
racy: 0.9565
Epoch 47/50
457/457 - 0s - loss: 0.2154 - accuracy: 0.9562 - val_loss: 0.2941 - val_accu
racy: 0.9565
Epoch 48/50
457/457 - 0s - loss: 0.2095 - accuracy: 0.9584 - val_loss: 0.2842 - val_accu
racy: 0.9565
Epoch 49/50
457/457 - 0s - loss: 0.2039 - accuracy: 0.9584 - val_loss: 0.2747 - val_accu
racy: 0.9652
Epoch 50/50
457/457 - 0s - loss: 0.1983 - accuracy: 0.9584 - val_loss: 0.2653 - val_accu
racy: 0.9652
```

Out[84]:

```
<tensorflow.python.keras.callbacks.History at 0x1f812bf8b00>
```

In [85]:

```
oversample_predictions = oversample_model.predict(original_Xtest, batch_size=200, verbose=0
```

In [86]:

```
oversample_fraud_predictions = oversample_model.predict_classes(original_Xtest, batch_size=
```

In [87]:

```
oversample_smote = confusion_matrix(original_ytest, oversample_fraud_predictions)
actual_cm = confusion_matrix(original_ytest, original_ytest)
labels = ['Д-кач.', 'З-кач.']

fig = plt.figure(figsize=(16,8))

fig.add_subplot(221)
plot_confusion_matrix(oversample_smote, labels, title="OverSample (SMOTE) \n Матрица ошибок

fig.add_subplot(222)
plot_confusion_matrix(actual_cm, labels, title="100% accuracy \n Матрица ошибок", cmap=plt.
```

```
Матрица ошибок без нормализации
[[68  3]
 [ 2 40]]
Матрица ошибок без нормализации
[[71  0]
 [ 0 42]]
```

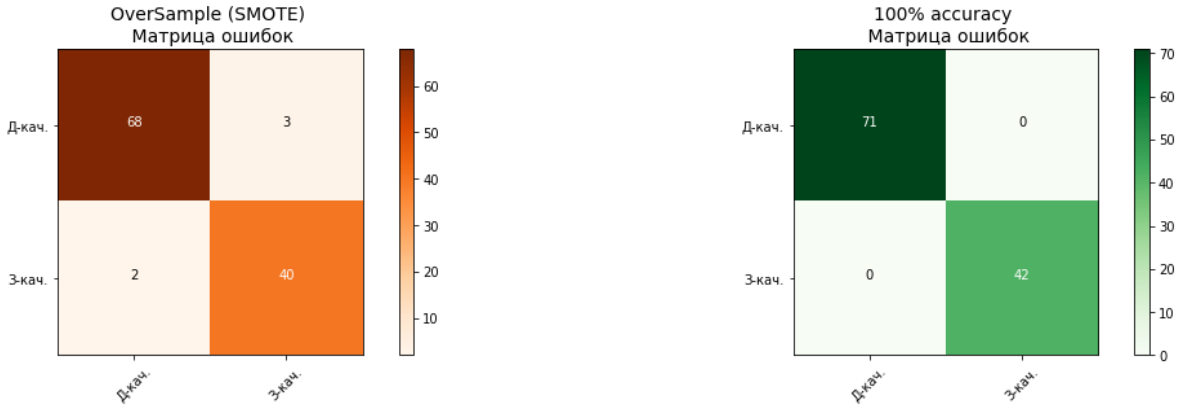

Заключение:

Использование техники SMOTE для несбалансированного набора данных помогло исправить дисбаланс классов. Тем не менее, иногда нейронная сеть в с избыточным набором данных (OverSample) делает меньше правильных предсказаний, чем модель, использующая уменьшенный набор данных (UnderSample).